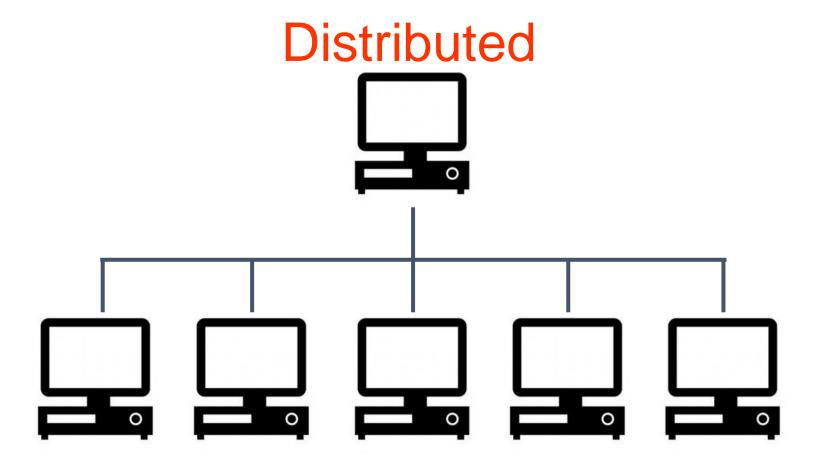


# Hadoop 개요

### Local vs Distributed

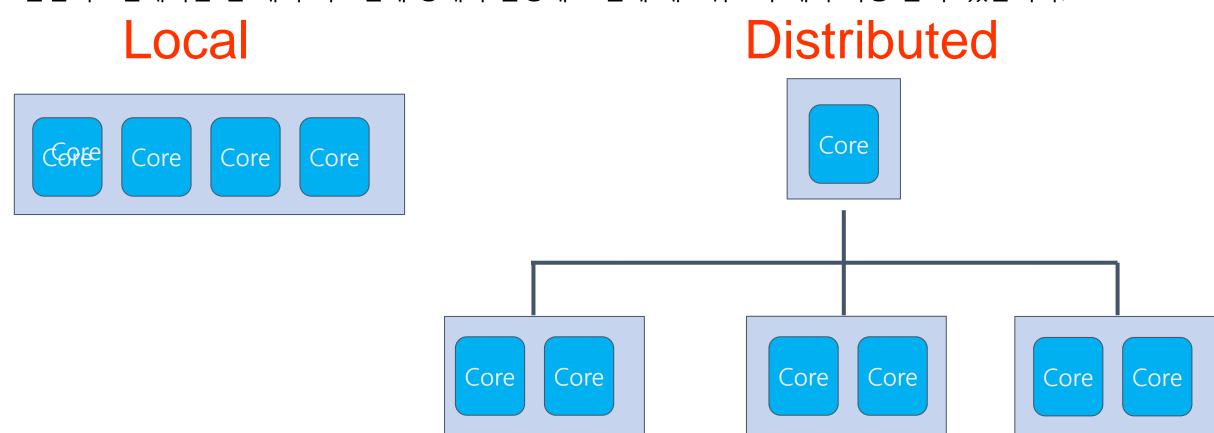
- 로컬 컴퓨터에서는 RAM 용량에 따라 0-32GB 범위의 데이터를 다룰 수 있습니다.
- 더 큰 데이터셋은 SQL 데이터베이스를 사용하여 스토리지를 사용하거나, 여러대의 컴퓨터로 구성된 분산시스템을 사용해야 합니다.





### Local vs Distributed

- 로컬 프로세스는 단일 시스템의 컴퓨팅 리소스를 사용합니다.
- 분산 프로세스는 네트워크를 통해 연결된 여러 머신의 컴퓨팅 리소스를 액세스 할 수 있습니다.
- 단일 머신을 Scale Up 하는 것보다 여러대의 머신으로 확장(Scale Out)하는 것이 더 쉽습니다.
- 분산시스템에서는 한 대의 시스템에 장애가 발생해도 전체 네트워크가 계속 작동 할 수 있습니다.



# Hadoop





**Application Layer** 



Other Applications

Resource Management Layer

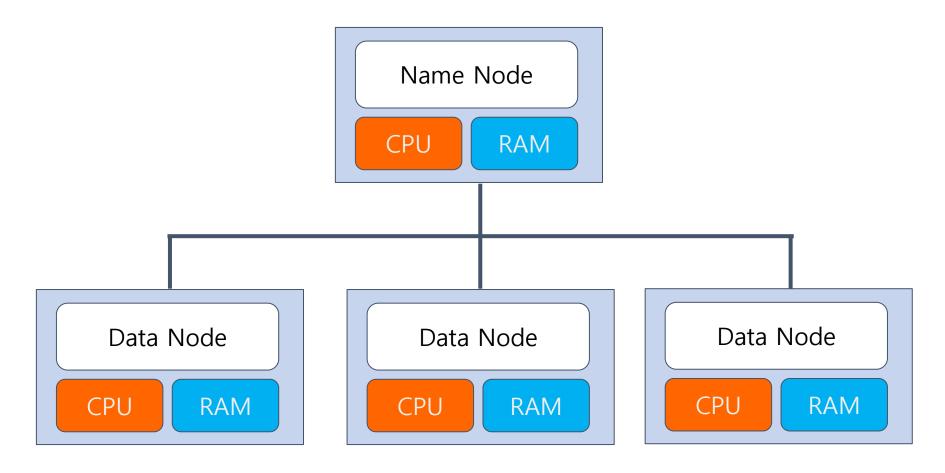


Storage Layer



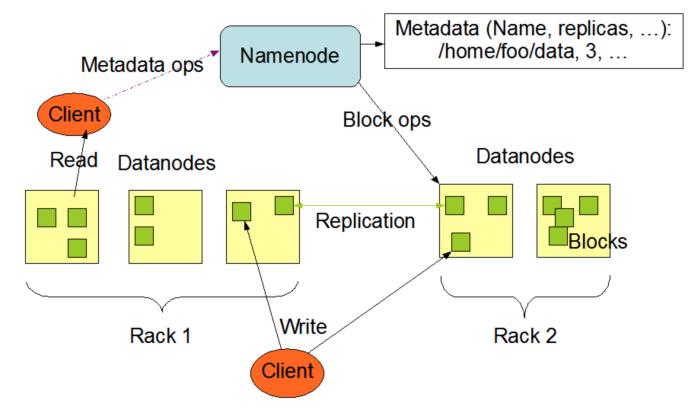
### HDFS (Hadoop Distributed File System)

- HDFS는 기본적으로 128MB 크기의 데이터 블록(block)을 사용하며, 각 블록은 최소 3개로 복제됩니다.
- 블록은 Fault Tolerance을 지원하는 방식으로 분산(distributed) 됩니다.
- 더 작은 블록은 처리 중에 더 많은 병렬화를 제공합니다.
- 블록의 여러 복사본이 노드 장애로 인한 데이터 손실을 방지합니다.



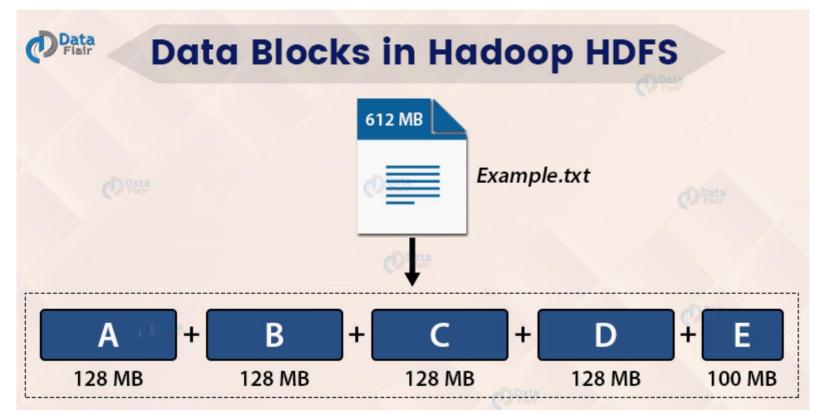
## HDFS - 아키텍처

- HDFS는 클러스터에 파일을 분산저장/관리하는 역할을 하며, Namenode, Datanode, Client 모듈로 구성
- Namenode는 전체적인 HDFS가 어떻게 구성되어 있는지, 어디에 어떤 블록이 저장되어 있는지 등 HDFS 의 메타 데이터를 관리하는 역할을 합니다.
- Datanode는 실제적으로 파일을 저장하는 역할을 합니다.
- Client는 사용자가 작성한 프로그램으로 이 HDFS에 파일을 쓰거나 읽는 작업을 요청합니다.



### HDFS - 파일 저장 방식

- HDFS는 파일을 분산 저장하기 위해서 먼저 파일의 메타 데이터와 컨텐츠 데이터를 분리합니다.
- 메타 데이터 : 파일의 접근 권한, 생성일, 수정일, 네임 스페이스 등 파일에 대해 설명하는 정보
- 컨텐츠 데이터: 실제 파일에 저장된 데이터
- 파일의 메타데이터는 네임 노드에 저장되며 컨텐츠 데이터는 블록 단위로 쪼개져서 데이터 노드에
- 블록의 기본 크기는 128MB이며, 최소 3개의 복사본을 생성하여 분산 저장합니다.



### HDFS - NameNode

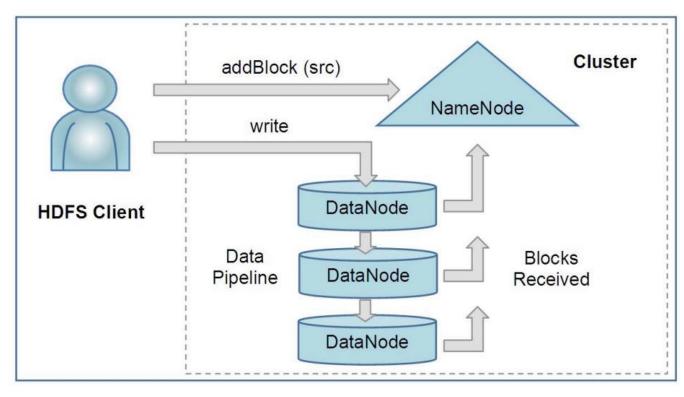
- 네임 노드는 파일의 메타 데이터를 inode에 저장합니다.
- inode란 unix 파일 시스템에서 사용되는 폴더 구조를 저장하는 구조체를 말합니다.
- 또한 네임 노드에는 파일 구성하는 블록들의 목록과 위치 정보가 저장되어 있습니다.
- 이러한 네임 노드는 HDFS에 파일을 읽거나 쓰는 작업의 시작점 역할을 수행합니다.

#### ■ 파일 읽기 작업

- 클라이언트는 네임 노드에 파일의 네임 스페이스에 해당하는 블록들의 목록과 주소를 요청
- 클라이언트는 가장 가까이 위치한 데이터 노드에서 블록을 읽어옴

#### ■ 파일 쓰기 작업

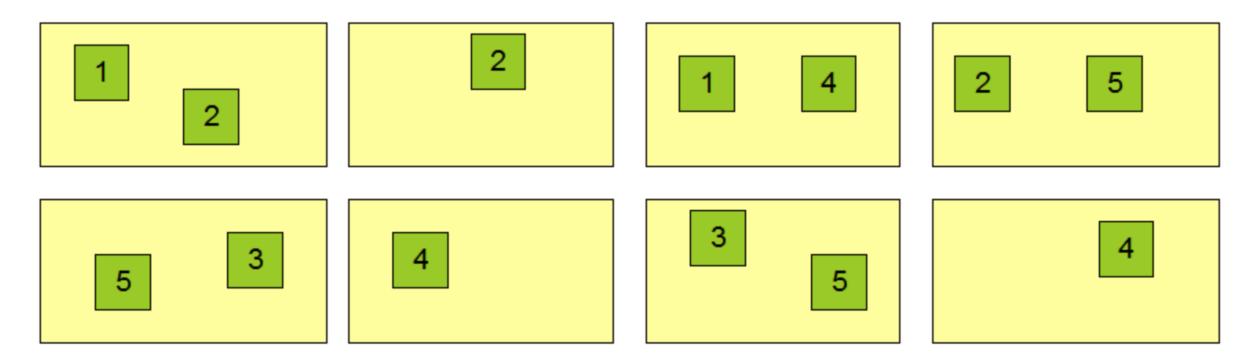
- 클라이언트는 네임 노드에게 어드 데이터 노드에 블록을 쓰면 좋을지 요청
- 2. 네임 노드가 데이터 노드를 할당
- 3. 클라이언트는 블록을 쓰기 위한 데이터 파이프라인 생성
- 4. 데이터 파이프라인을 이용해서 블록 쓰기 작업 수행



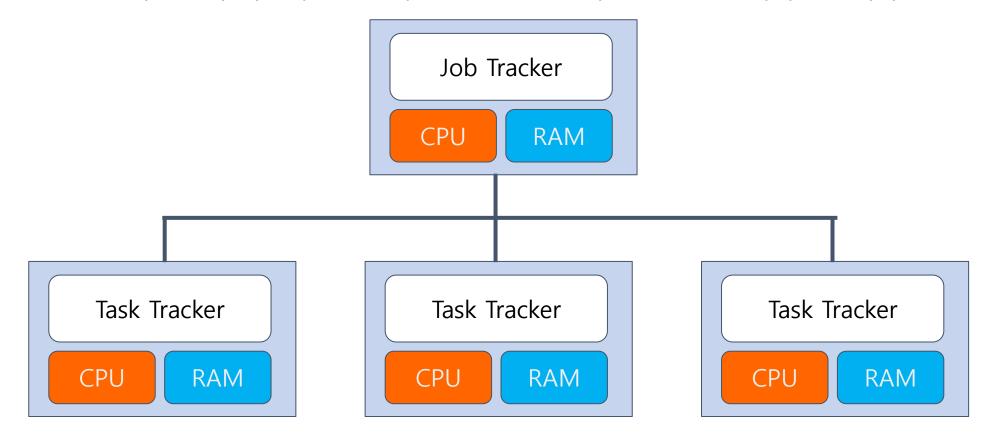
## HDFS - Datanode

- 파일의 컨텐츠 데이터는 블록 단위로 나뉘며, 블록의 기본 크기는 128MB이며 최소 3개의 복사본을 생성 하여 분산 저장합니다.
- 데이터 노드는 그 중 하나의 복사본을 저장하는 것입니다.

### Datanodes



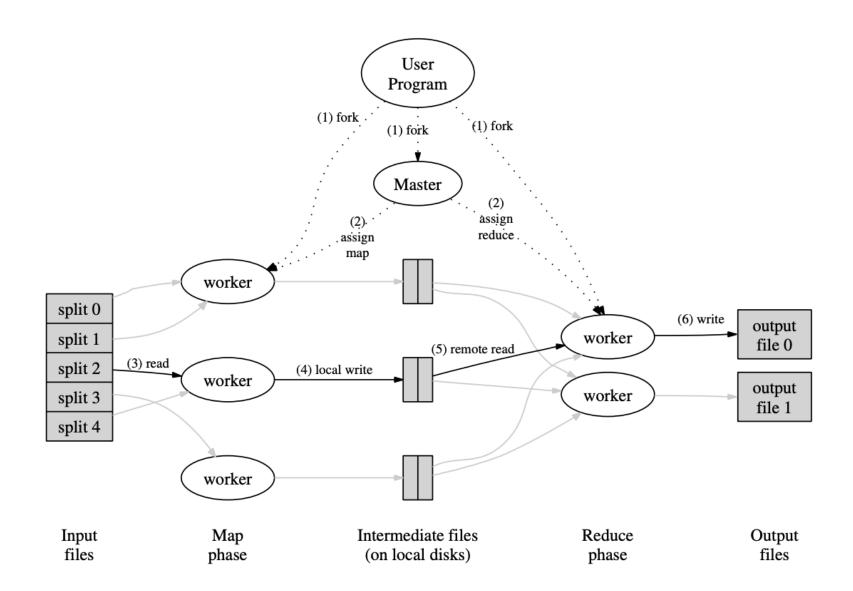
- MapReduce는 Computation Task를 분산 된 파일셋(예: HDFS)으로 분할하는 방법입니다..
- Job Tracker와 여러 Task Tracker로 구성됩니다.
- Job Tracker는 Task Tracker에서 실행할 코드를 보냅니다.
- Job Tracker 는 Task에 CPU와 메모리를 할당하고 Worker 노드의 Task 들을 모니터링 합니다.



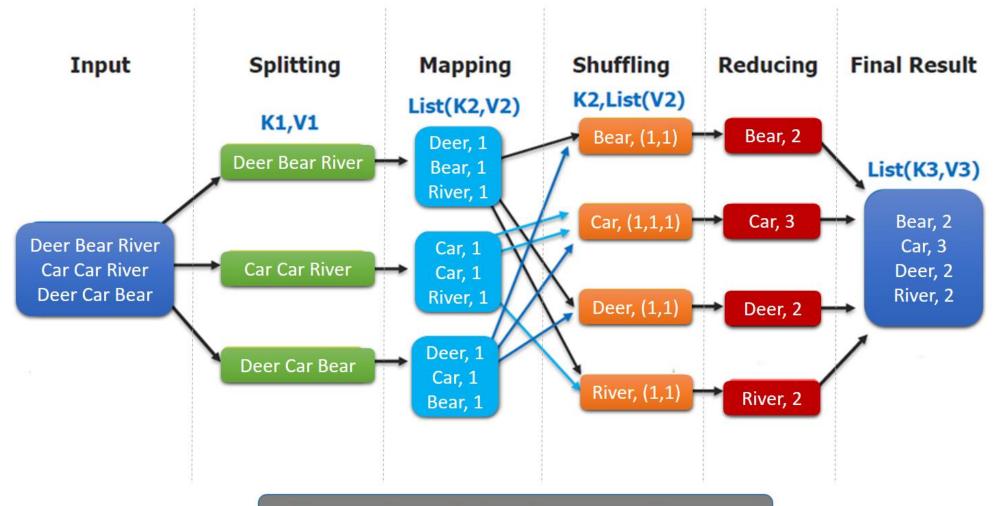
- 맵 리듀스는 구글 내부에서 크롤링 된 문서, 로그 등 방대한 양의 raw data를 분석하는 과정에서 느낀 불편함에서 출발했습니다.
- 프로그램 로직 자체는 단순한데 입력 데이터의 크기가 워낙 커서 연산을 하나의 물리 머신에서 수행할 수 가 없었습니다.
- 이 거대한 인풋 데이터를 쪼개어 수많은 머신들에게 분산시켜서 로직을 수행한 다음 결과를 하나로 합치자는 것이 핵심 아이디어 입니다.
- MapReduce 프레임워크에서 개발자가 코드를 작성하는 부분은 map과 reduce 두 가지 함수입니다.
- map은 전체 데이터를 쪼갠 청크에 대해서 실제로 수행할 로직입니다.
- reduce는 분산되어 처리된 결과 값들을 다시 하나로 합쳐주는 과정이며, 이 역시 분산된 머신들에서 병렬 적으로 수행됩니다.

### ■ MapReduce 수행 절차

- 1. 쪼개기(Split): 크기가 큰 인풋 파일을 작은 단위의 청크들로 나누어 분산 파일 시스템(ex. HDFS)에 저장합니다.
- 2. 데이터 처리하기(Map): 잘게 쪼개어진 파일을 인풋으로 받아서 데이터를 분석하는 로직을 수행합니다.
- 3. 처리된 데이터 합치기(Reduce): 처리된 데이터를 다시 합칩니다.



### 3대의 Mapper와 4대의 Reducer 노드로 이루어진 클러스터에서 워드 카운팅을 수행하는 예시



MapReduce Word Count Process

# Hadoop 설치

### VirtualBox 설치

### https://www.virtualbox.org/



■ Oracle VM VirtualBox

### VirtualBox Welcome to VirtualBox.org!

About Screenshots Downloads

Documentation End-user docs

Technical docs

Contribute

Community

VirtualBox is a powerful x86 and AMD64/Intel64 virtualization product for enterprise as well as home use. Not only is VirtualBox an extremely feature rich, high performance product for enterprise customers, it is also the only professional solution that is freely available as Open Source Software under the terms of the GNU General Public License (GPL) version 2. See "About VirtualBox" for an introduction.

Presently, VirtualBox runs on Windows, Linux, Macintosh, and Solaris hosts and supports a large number of guest operating systems including but not limited to Windows (NT 4.0, 2000, XP, Server 2003, Vista, Windows 7, Windows 8, Windows 10), DOS/Windows 3.x, Linux (2.4, 2.6, 3.x and 4.x), Solaris and OpenSolaris, OS/2, and OpenBSD.

VirtualBox is being actively developed with frequent releases and has an ever growing list of features, supported guest operating systems and platforms it runs on. VirtualBox is a community effort backed by a dedicated company: everyone is encouraged to contribute while Oracle ensures the product always meets professional quality criteria.



#### Hot picks:

- Pre-built virtual machines for developers at 

  → Oracle Tech Network
- Hyperbox Open-source Virtual Infrastructure Manager → project site
- phpVirtualBox AJAX web interface ⇒ project site

■ 설치방법 참고: https://bit.ly/2T2rR7L

### VirtualBox 6.1.20 platform packages

- ➡Windows hosts
- •
- ⇒OS X hosts
- Linux distributions
- BSolaris hosts
- ➡Solaris 11 IPS hosts

### VirtualBox 6.1.20 platform packages

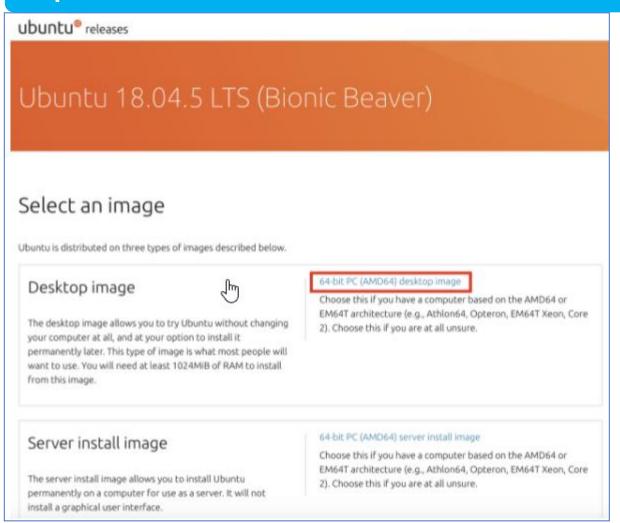
- ➡Windows hosts
- B→OS X hosts



- Linux distributions
- B Solaris hosts
- ➡Solaris 11 IPS hosts

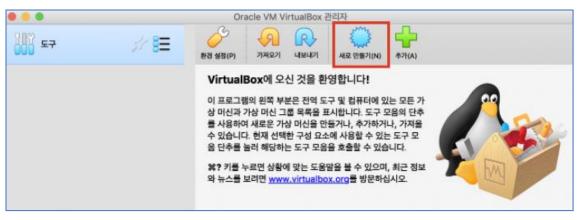
### Ubuntu 설치(참고)

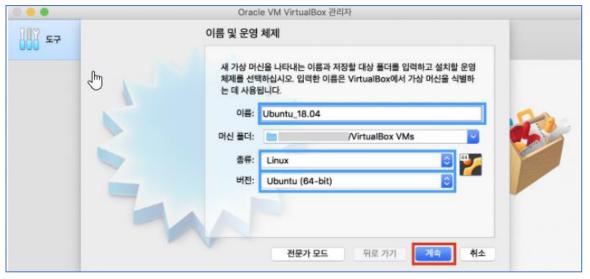
### http://mirror.kakao.com/ubuntu-releases/bionic/



### ■ 설치방법 참고

https://soobarkbar.tistory.com/215





# Spark 설치 (참고)

#### ■ 시스템 패키지 업데이트

sudo apt update sudo apt -y upgrade

#### ■ Java 설치

sudo apt-get install openjdk-8-jdk java -version

### ■ Apache Hadoop 다운로드 및 설치

wget https://downloads.apache.org/hadoop/common/hadoop-3.3.0/hadoop-3.3.0.tar.gz --no-check-certificate tar zxvf hadoop-3.3.0.tar.gz

설정방법 https://eyeballs.tistory.com/420 참고

### ■ Apache Spark 다운로드 및 설치

wget https://downloads.apache.org/spark/spark-3.1.1/spark-3.1.1-bin-hadoop3.2.tgz --no-check-certificate tar zxvf spark-3.1.1-bin-hadoop3.2.tgz

설정방법 <u>https://eyeballs.tistory.com/422</u> 참고

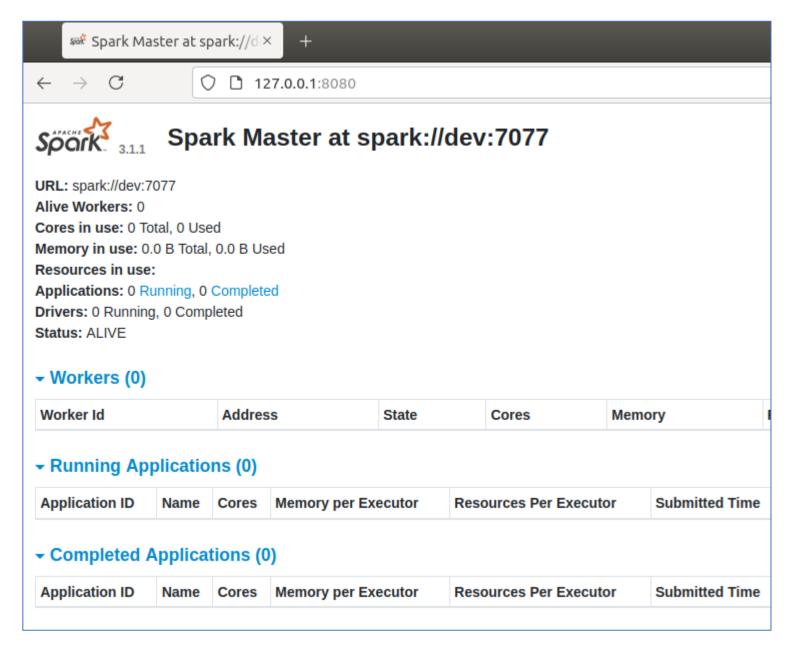
# Spark 설치 (참고)

■ Standalone Master Server 시작

start-master.sh sudo ss -tunelp | grep 8080

■ Spark Worker Process 시작

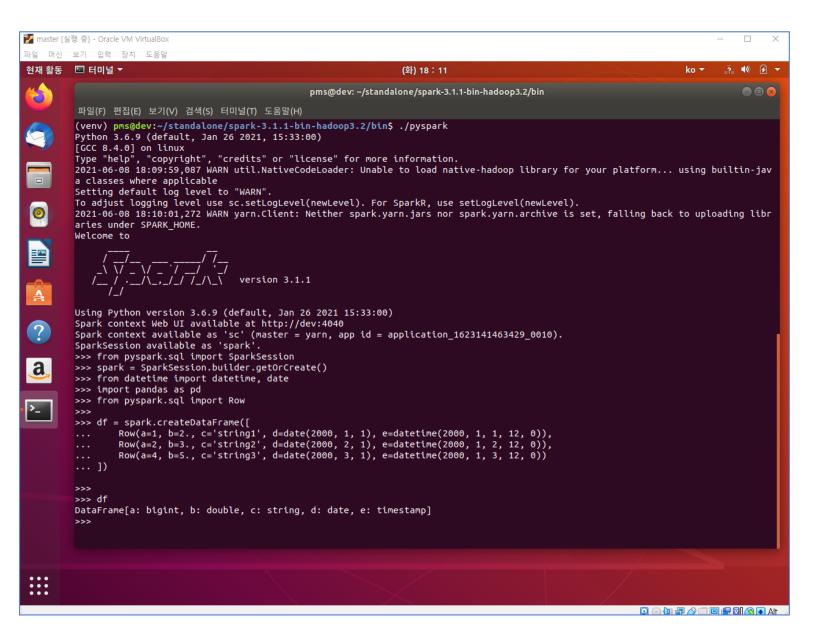
start-worker.sh spark://127.0.0.1:7077



# Spark 설치 (참고)

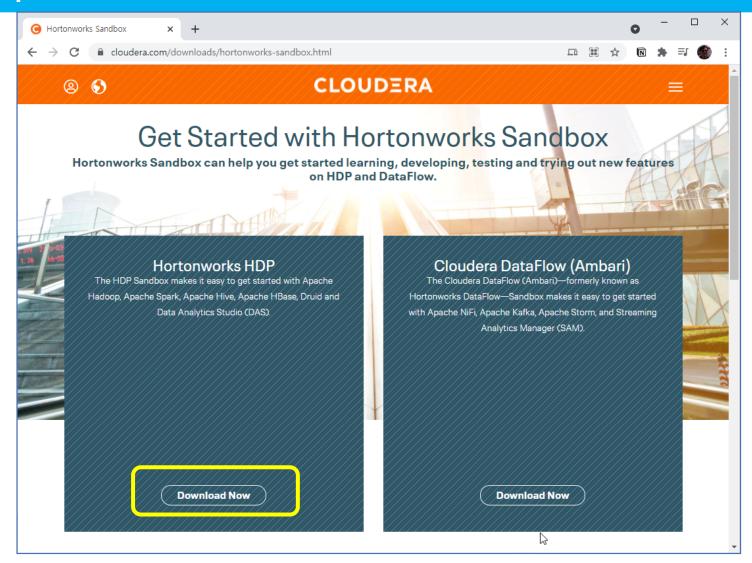
- Spark shell 사용
  SPARK\_HOME/bin/spark-shell
- PySpark shell 사용(파이썬)
  SPARK\_HOME/bin/pyspark
- Spark 정지

SPARK\_HOME/sbin/stop-slave.sh SPARK\_HOME/sbin/stop-master.sh

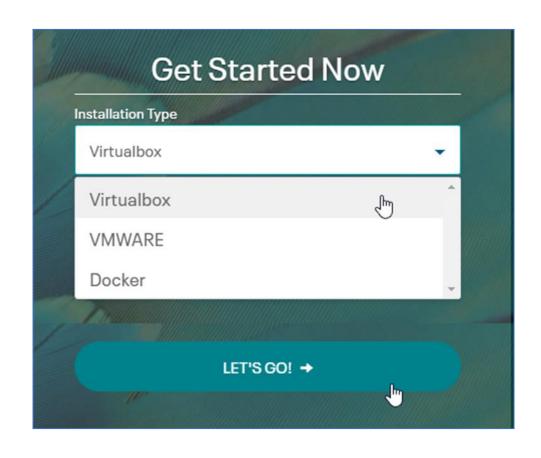


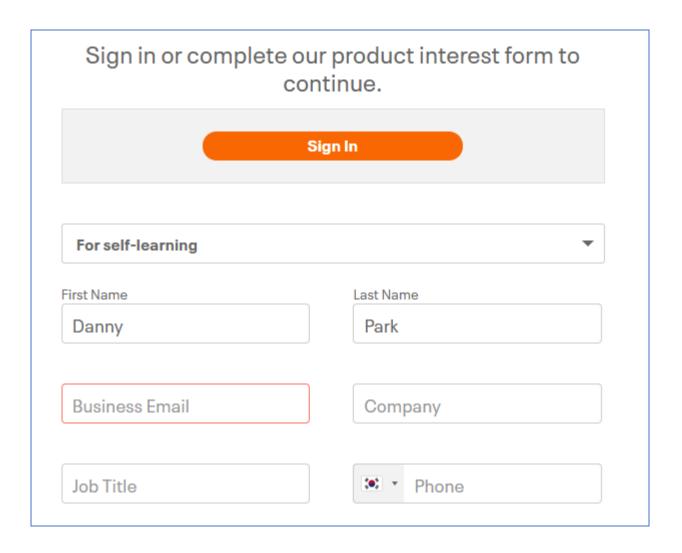
# HDP(Hortonworks Data Platform) 다운로드

### https://www.cloudera.com/downloads/hortonworks-sandbox.html



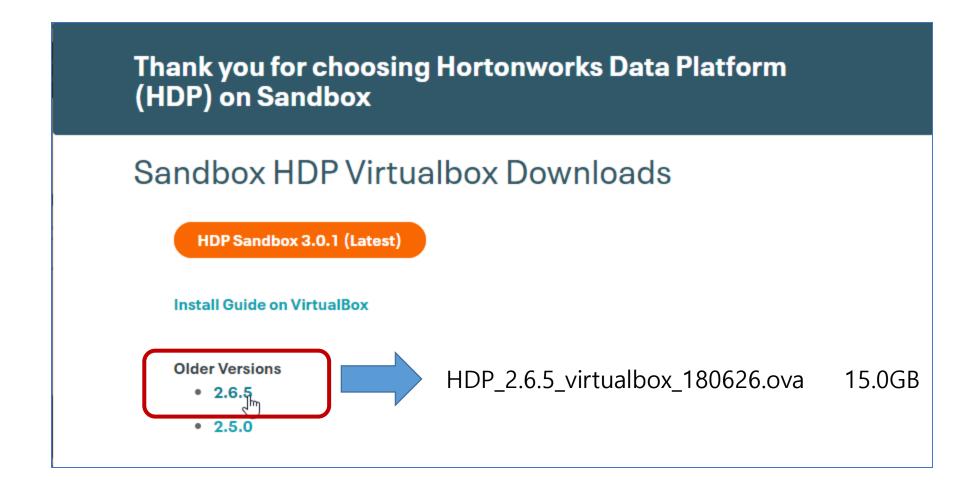
# HDP 다운로드





■ 참고 <a href="https://sungwoonblog.tistory.com/1">https://sungwoonblog.tistory.com/1</a>

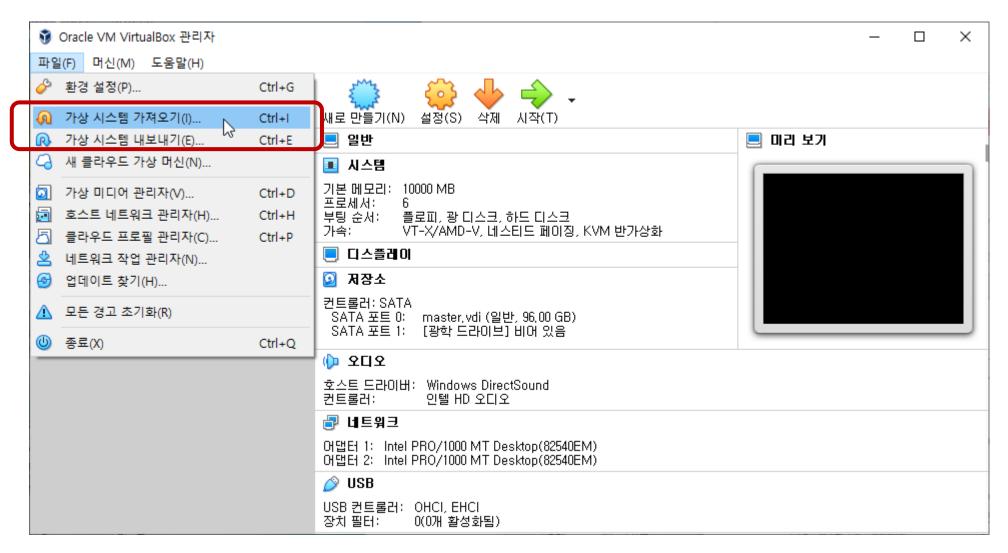
## HDP 다운로드



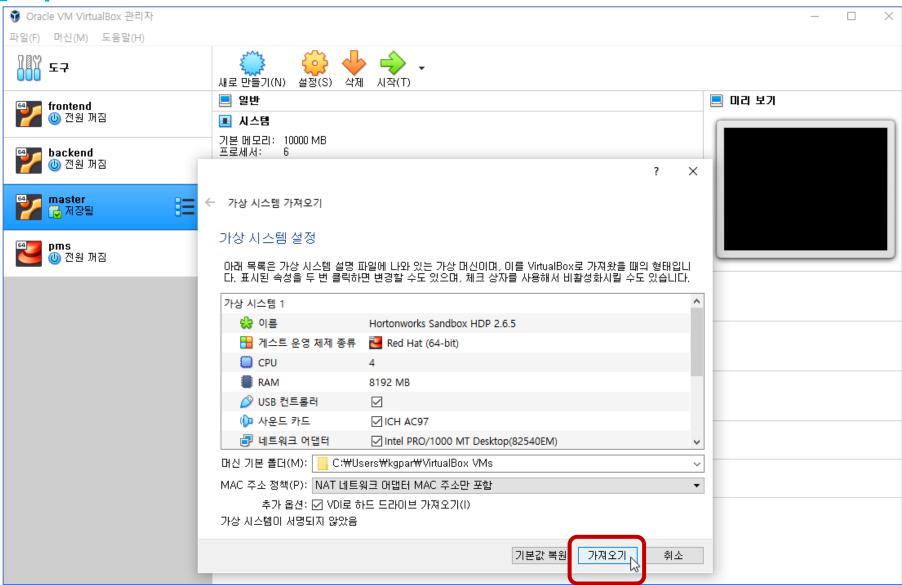
### HDP 설치

#### ■ VirtualBox 실행





### HDP 설치



### HDP 설치

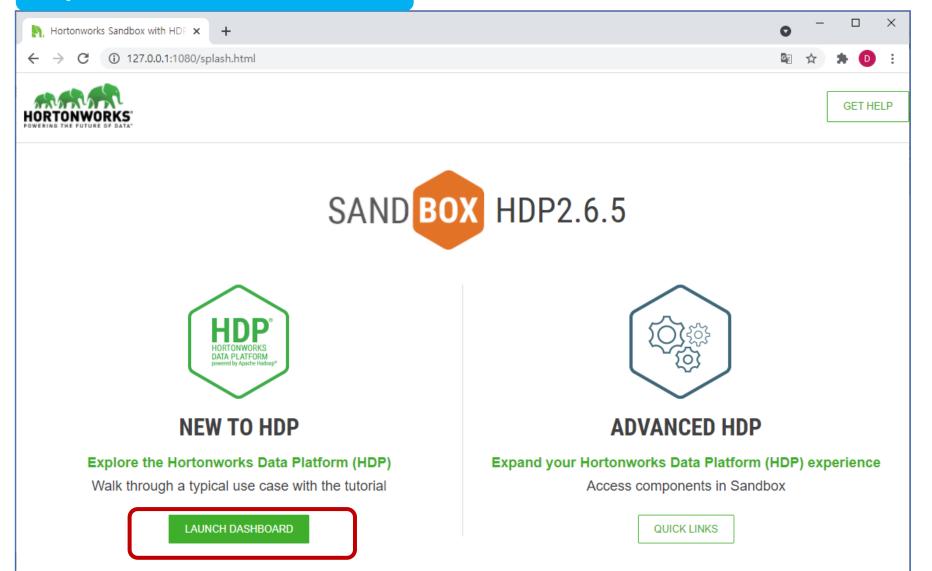
```
🊰 Hortonworks Sandbox HDP 2.6.5 [실행 중] - Oracle VM VirtualBox
 파잌 머시 보기 인련 장치 도운막
Please wait while the Hortonworks Sandbox is extracted and deployed.
This process will only occur once.
Grab a drink - this may take a few minutes.
While you wait, read up on interesting data articles here:
https://community.hortonworks.com/kb/list.html
Extracting and loading the Hortonworks Sandbox...
43e653f84b79: Loading layer 207.2MB/207.2MB
5d01fe42e1ab: Loading layer 29.18kB/29.18kB
7de498deb60f: Loading layer 81.72MB/81.72MB
396014a08347: Loading layer 1.088GB/1.088GB
2612153088bb: Loading layer 64.69MB/64.69MB
31be5f7a6a9c: Loading layer 25.68MB/25.68MB
2bc9d527476a: Loading layer 22.21MB/22.21MB
667193801922: Loading layer 6.144kB/6.144kB
2e7b704d9009: Loading layer 4.096kB/4.096kB
7d5046d89fa8: Loading layer 4.096kB/4.096kB
7a7883c3844f: Loading layer 3.072kB/3.072kB
1952e8b68e3f: Loading layer 3.584kB/3.584kB
81e482297d63: Loading layer 8.192kB/8.192kB
01c16e796873: Loading layer 155.4MB/1.986GB
```

🔼 🕼 🗗 🥟 🦳 🖭 😭 🐼 🚫 💽 Alt

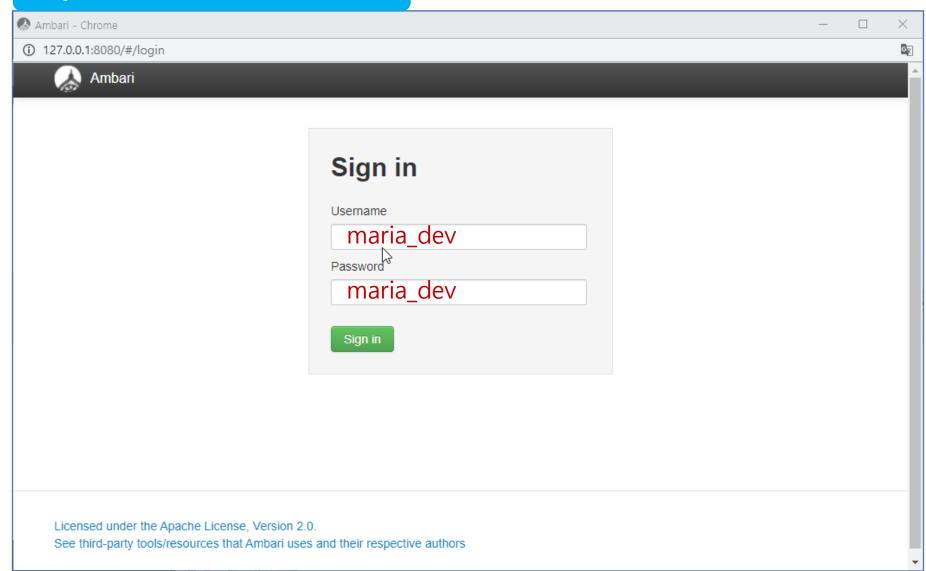
```
🊰 Hortonworks Sandbox HDP 2.6.5 [실행 중] - Oracle VM VirtualBox
파일 머신 보기 입력 장치 도움말
 Hortonworks HDP Sandbox
 https://hortonworks.com/products/sandbox
 To quickly get started with the Hortonworks Sandbox, follow this tutorial:
 https://hortonworks.com/tutorial/hadoop-tutorial-getting-started-with-hdp/
 To initiate your Hortonworks Sandbox session, open a browser to this address:
For Hintus IRove
     Welcome screen: http://localhost:1080
     SSH: http://localhost:4200
 For UMWare:
     Welcome screen: http://10.0.2.15:1080
     SSH: http://10.0.2.15:4200
```

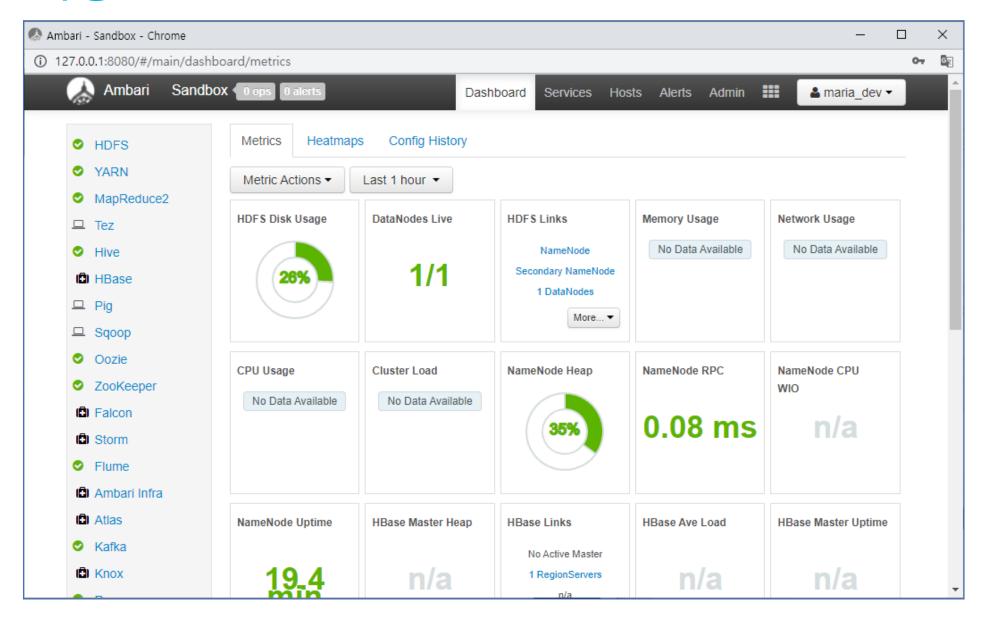
🙆 🕼 🗗 🥟 🧰 🖭 😭 🚺 🚫 💽 Alt

### http://127.0.0.1:1080/



### http://127.0.0.1:8080/

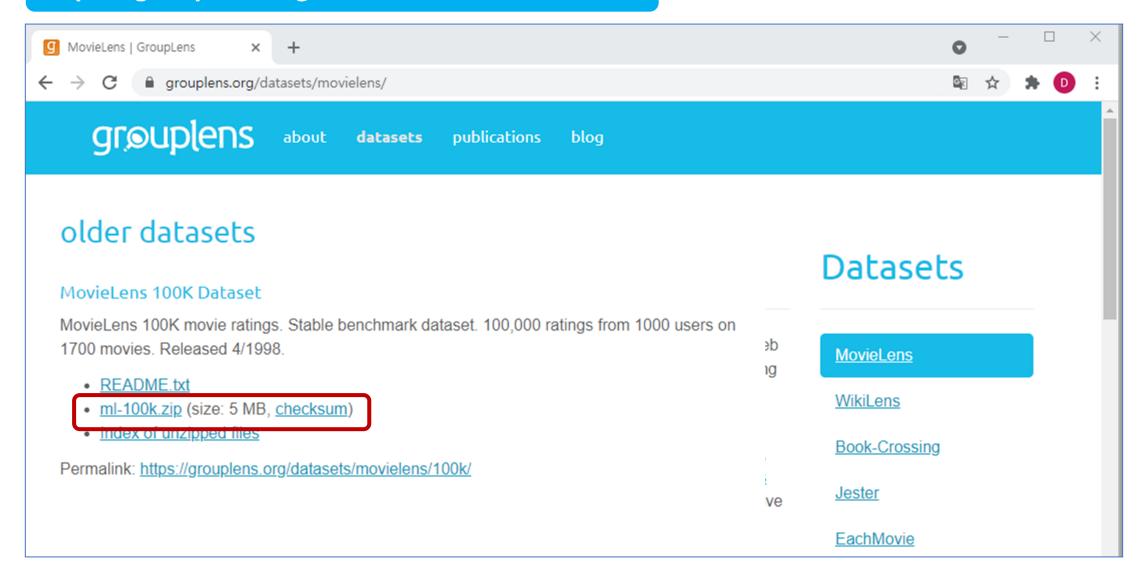




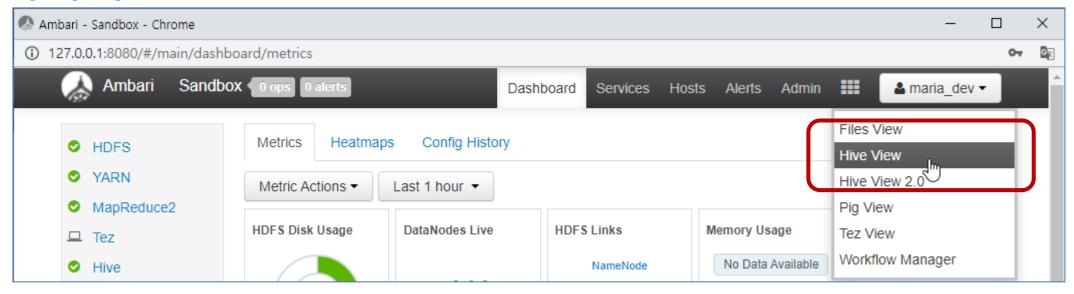
# Hadoop 실습

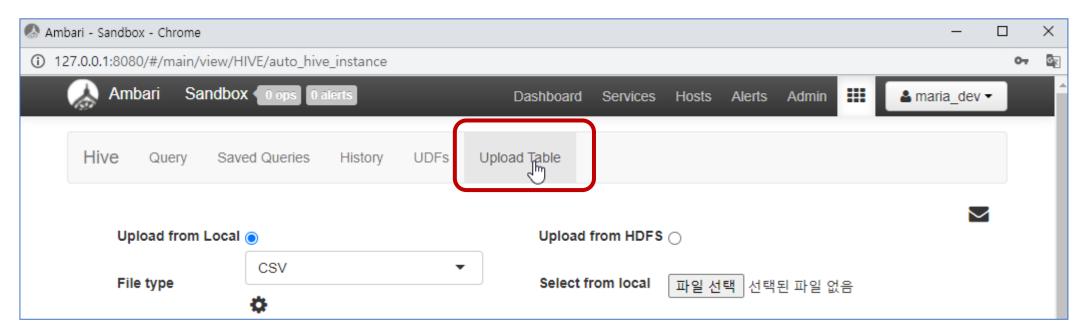
### MovieLens 데이터 실습

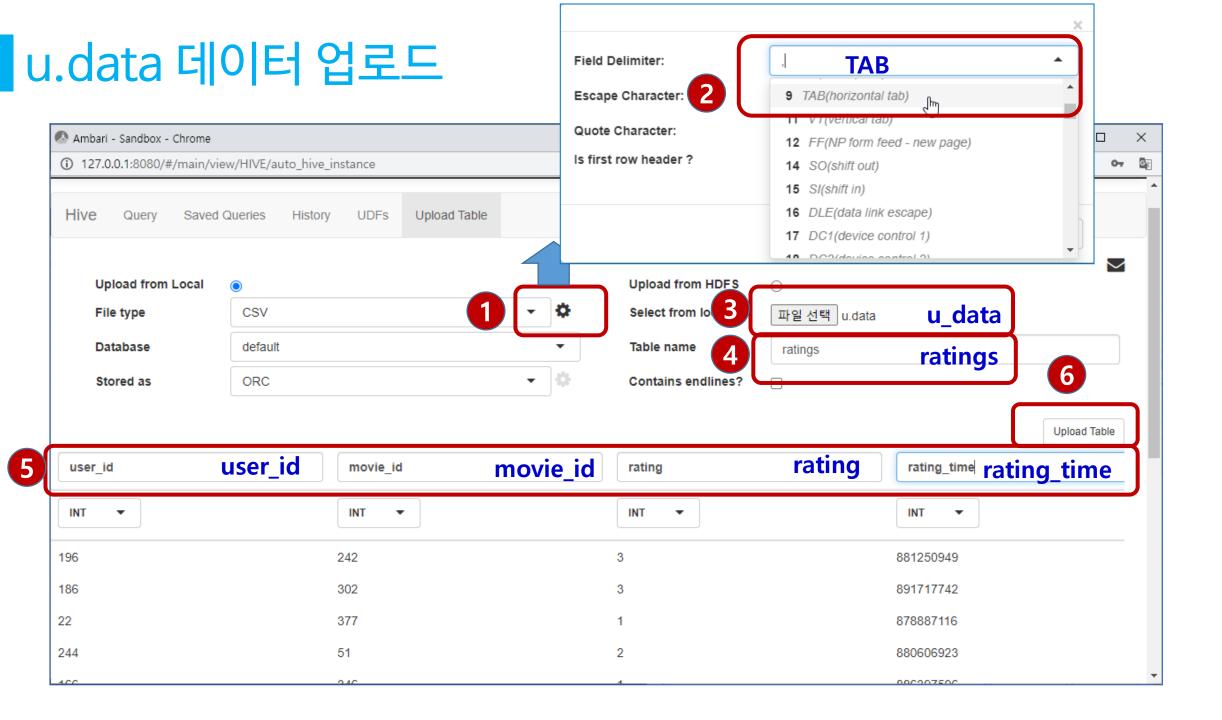
### https://grouplens.org/datasets/movielens/

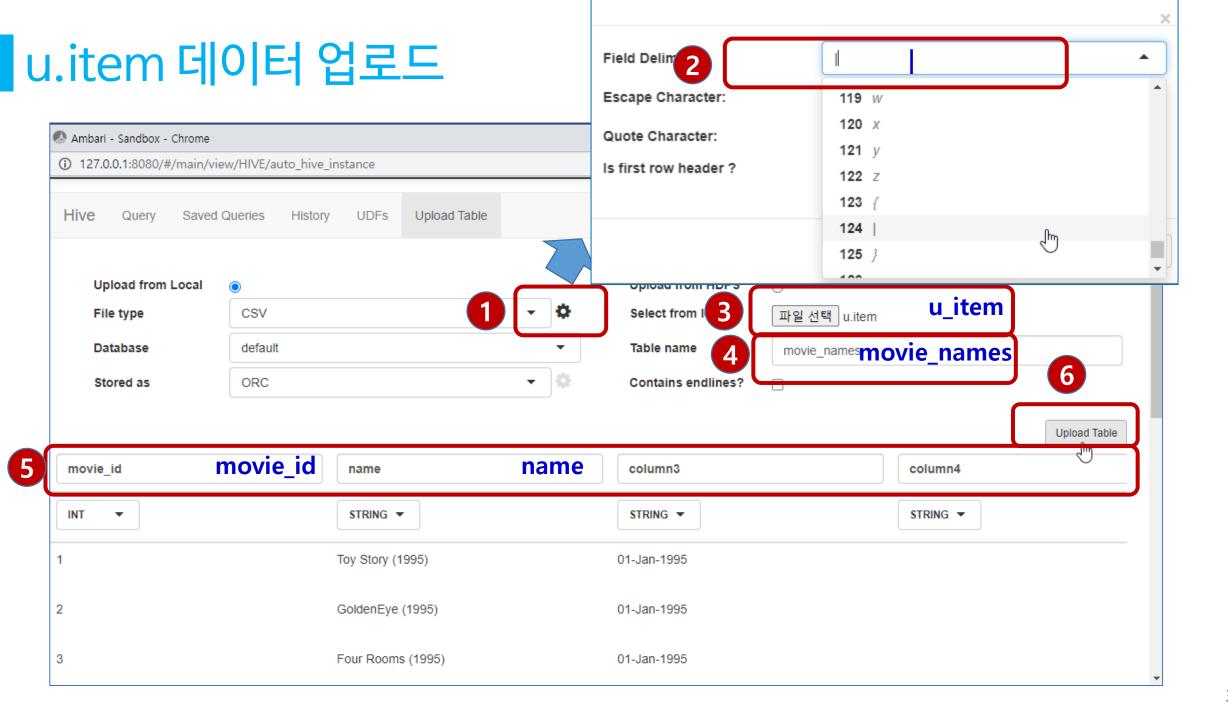


### 데이터 업로드

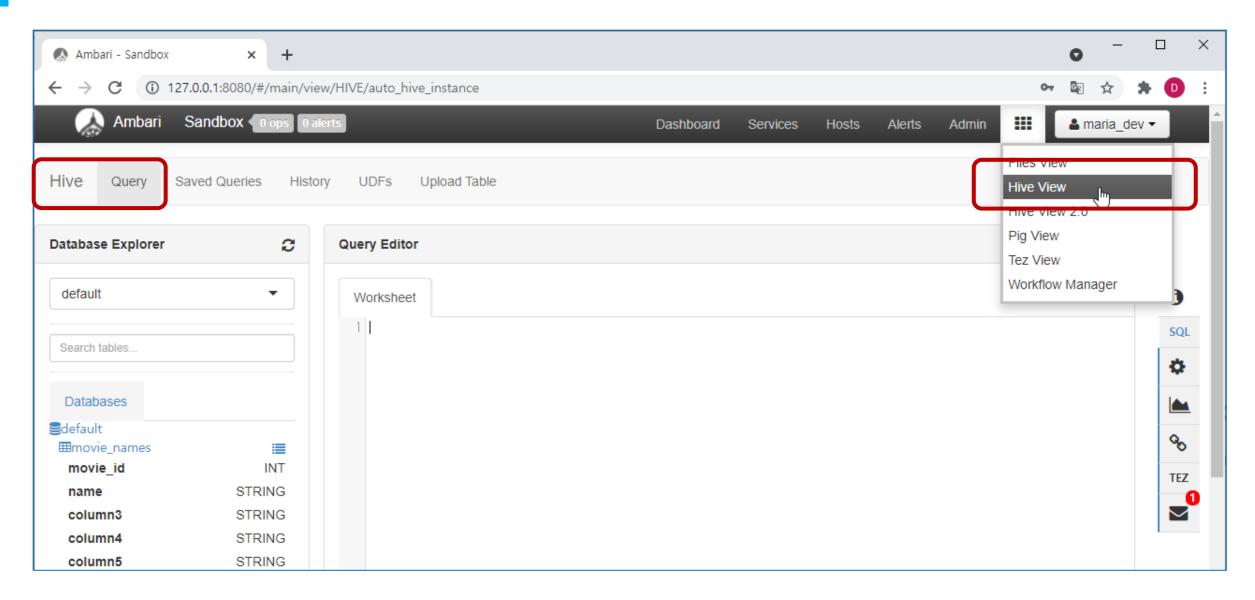




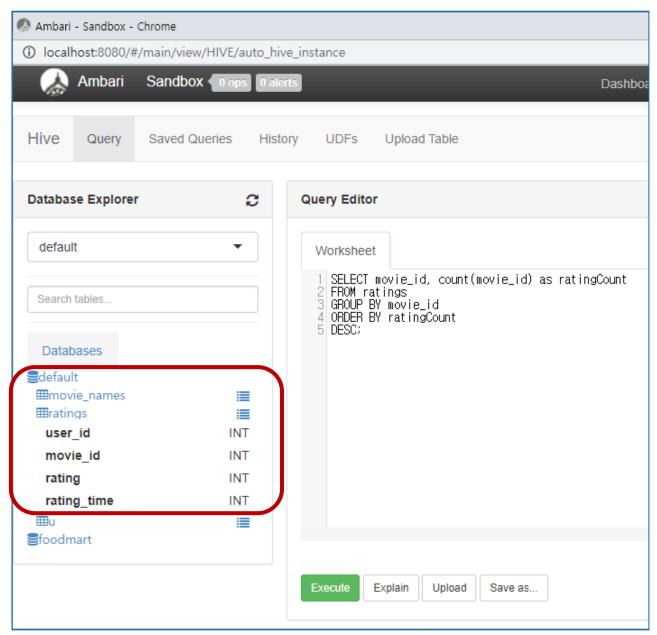




### Hive

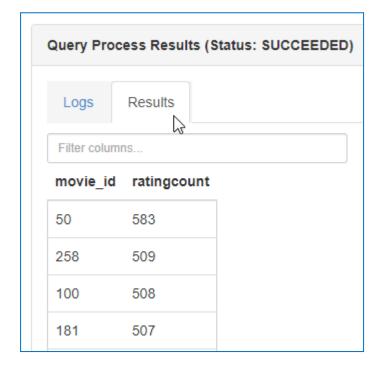


#### Hive

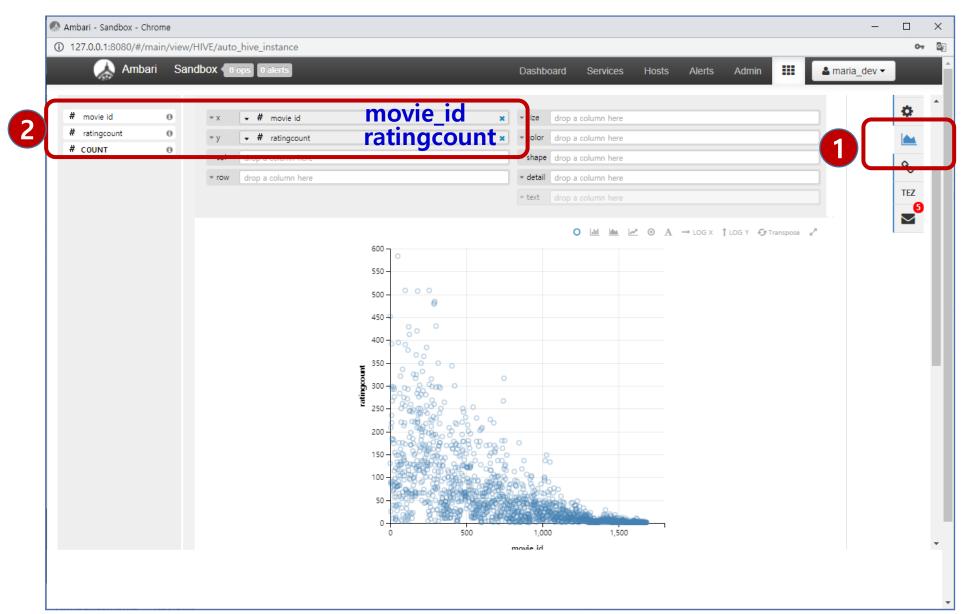


SELECT movie\_id, count(movie\_id) as ratingCount FROM ratings GROUP BY movie\_id ORDER BY ratingCount DESC;

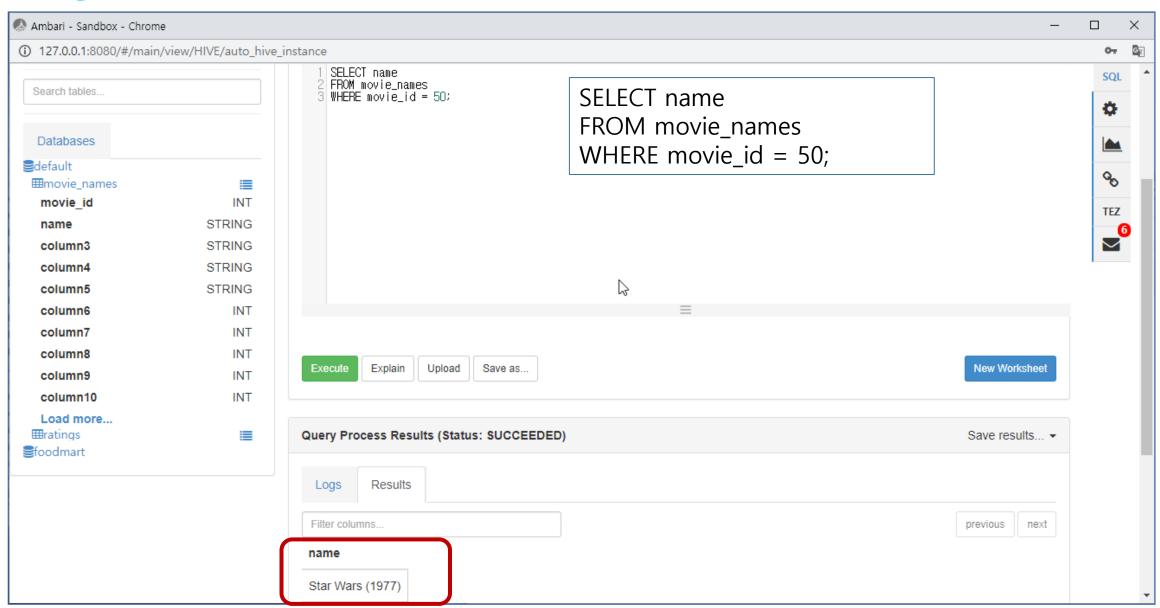


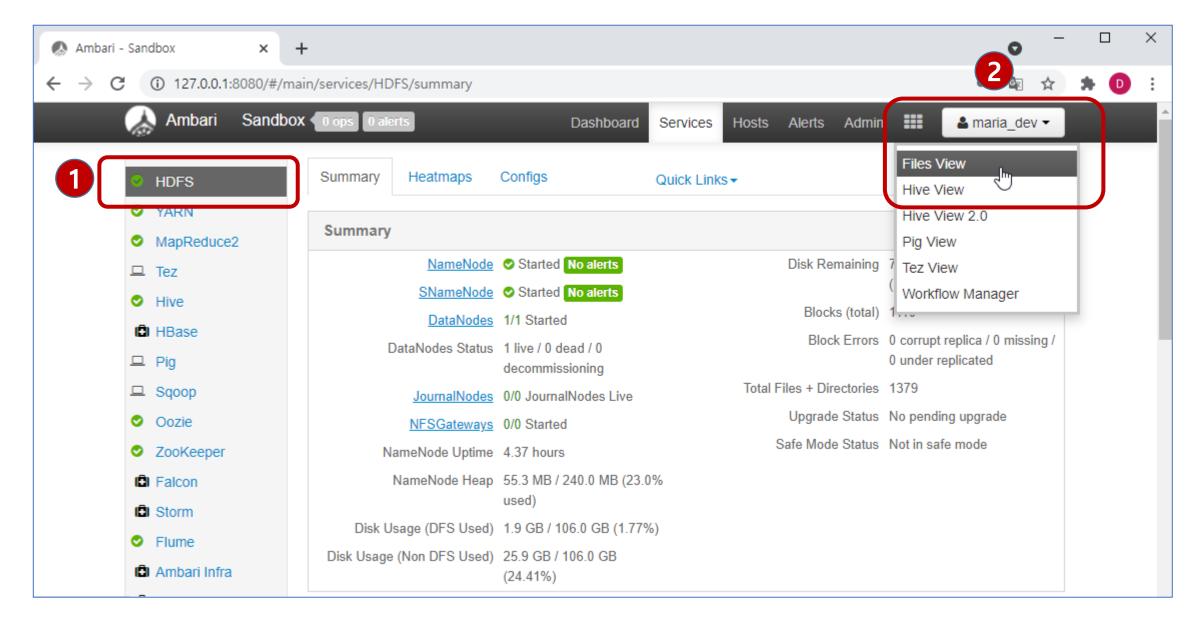


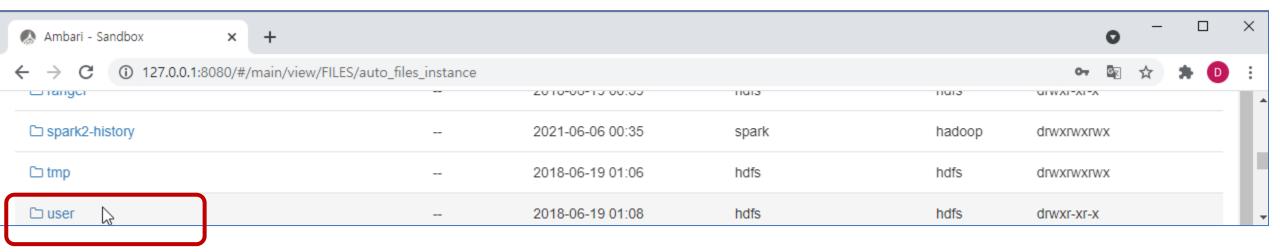
## Hive

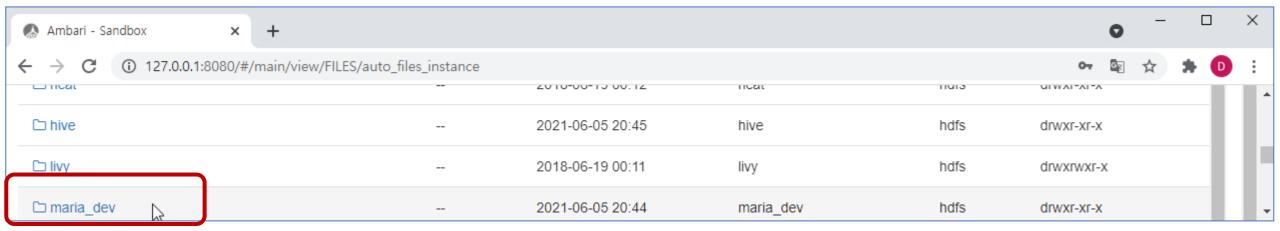


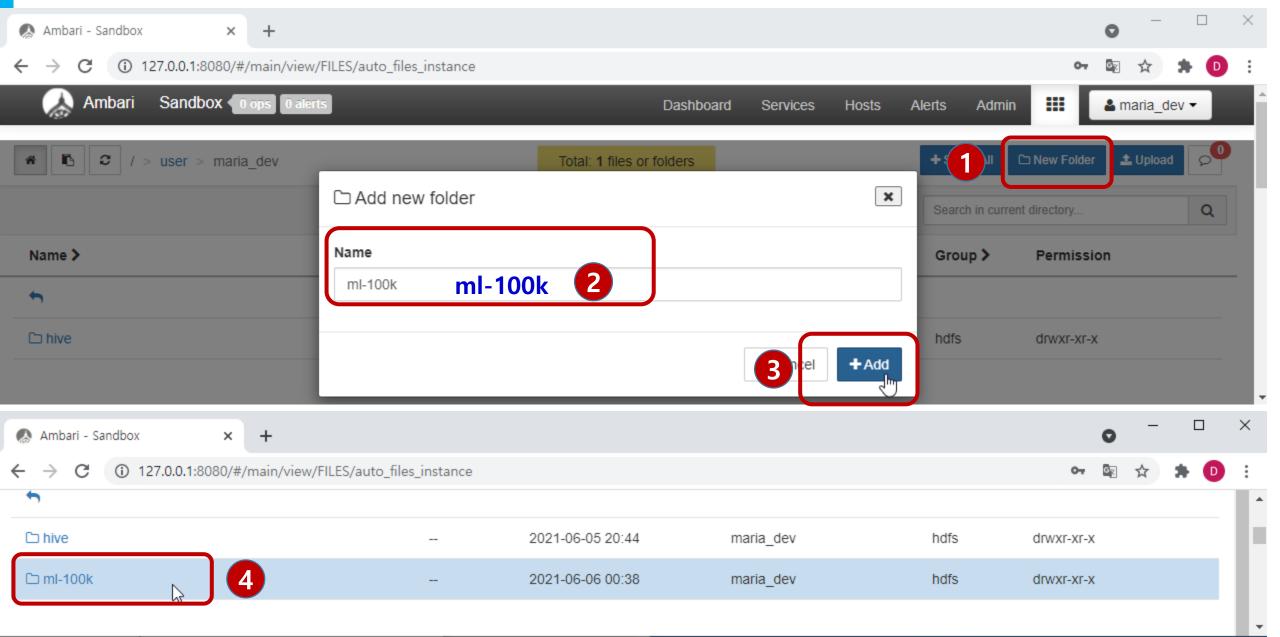
#### Hive

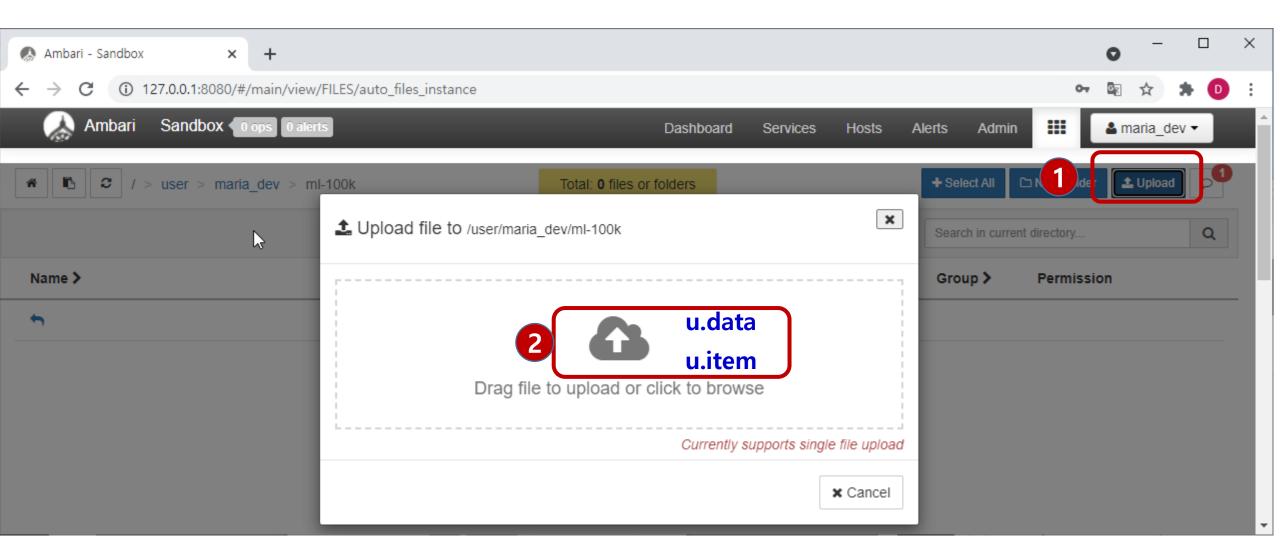


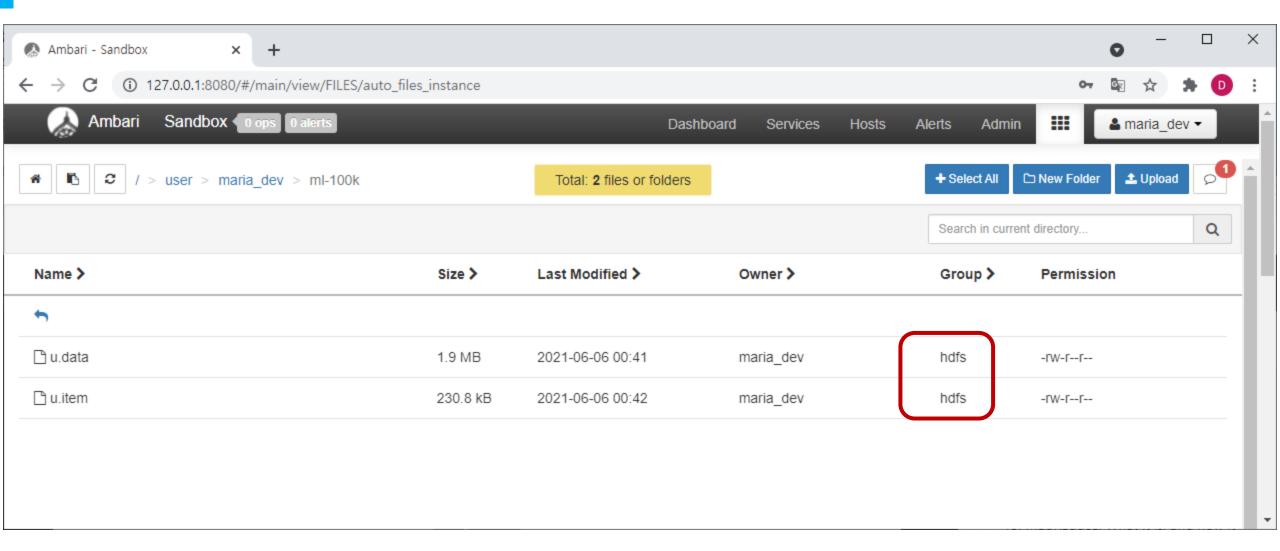


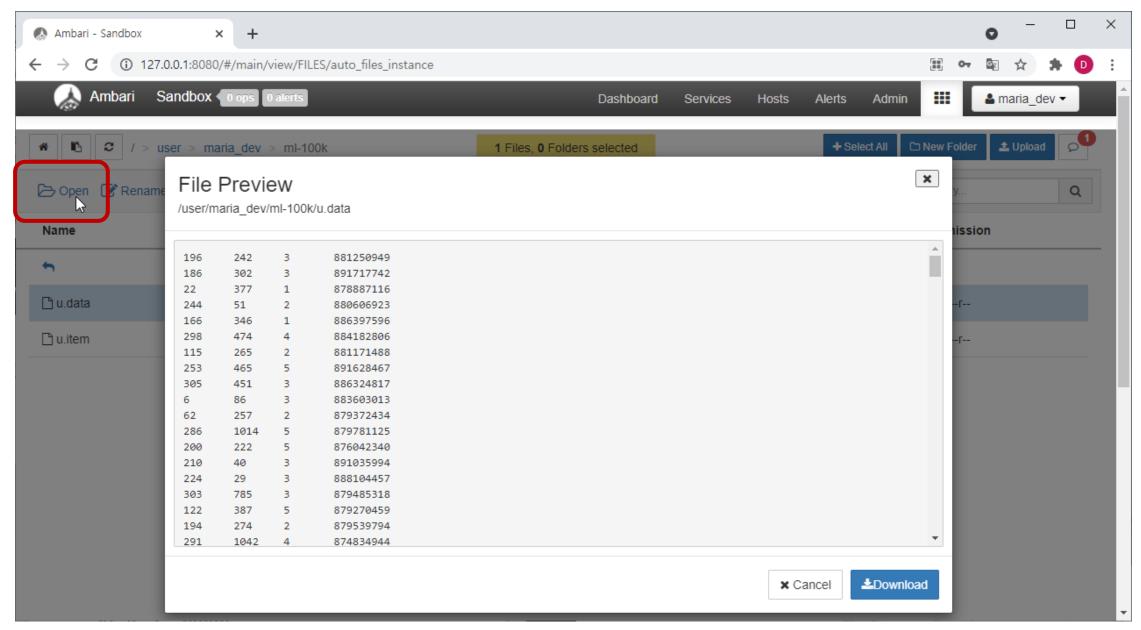


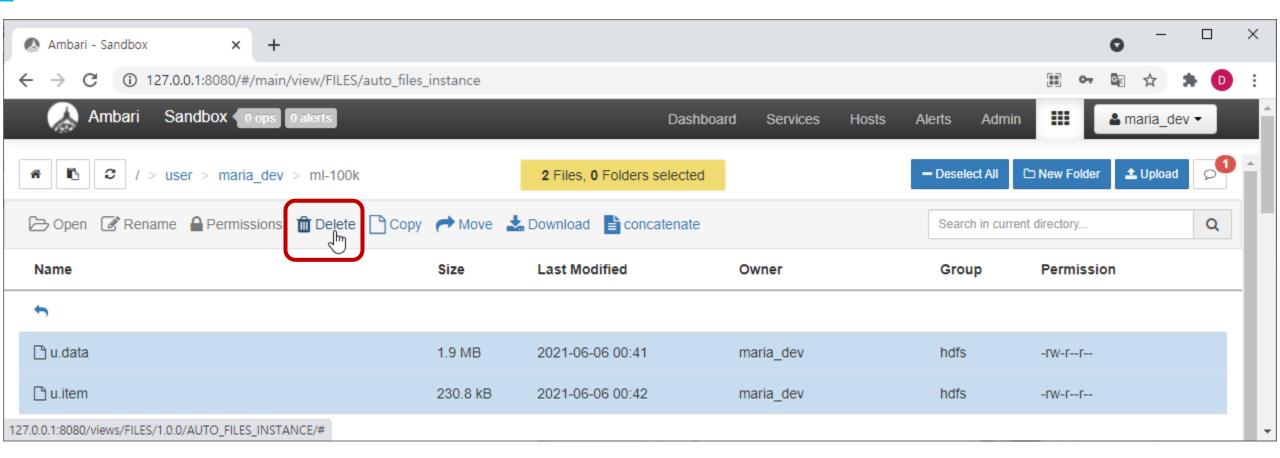


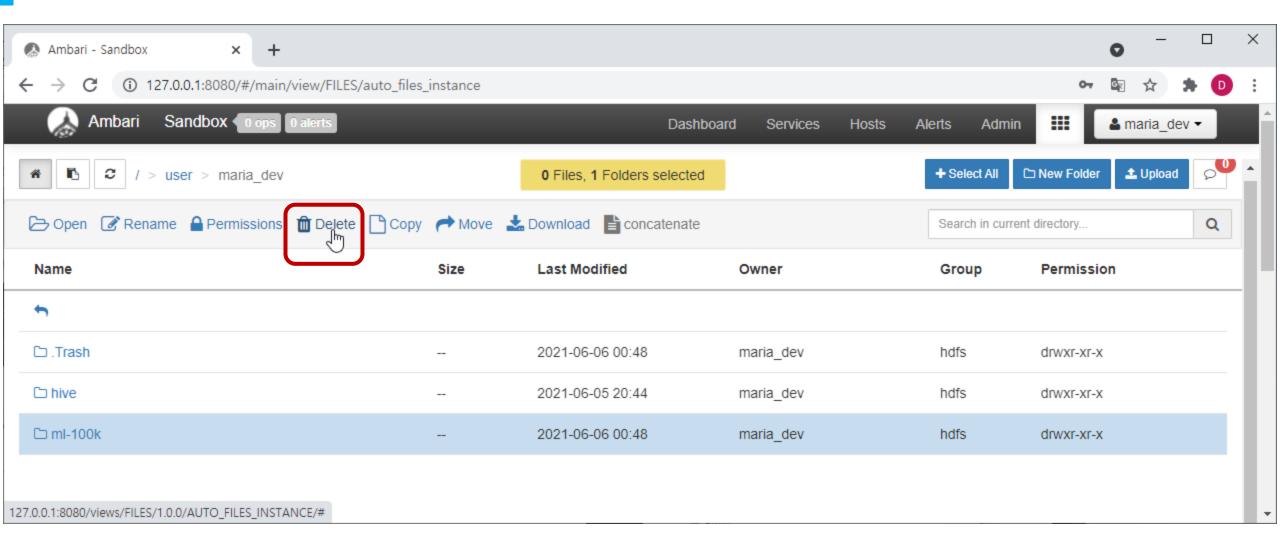




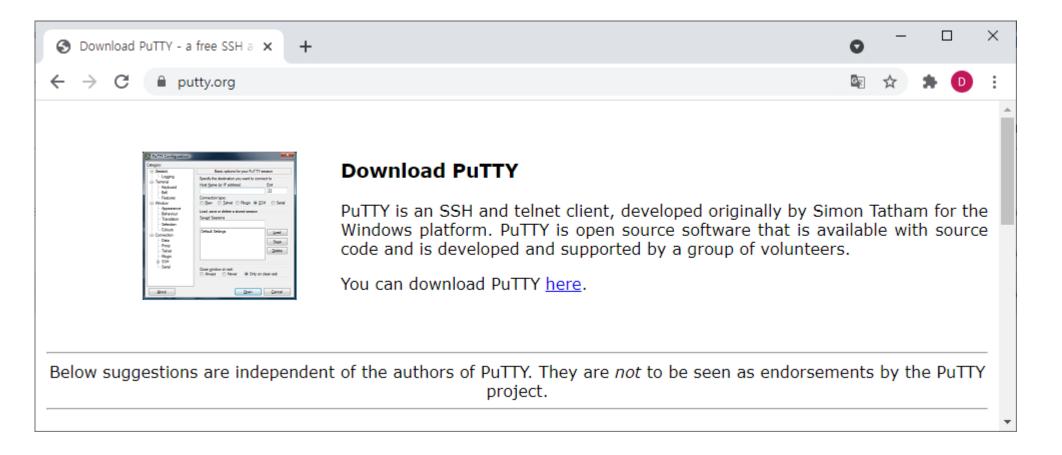






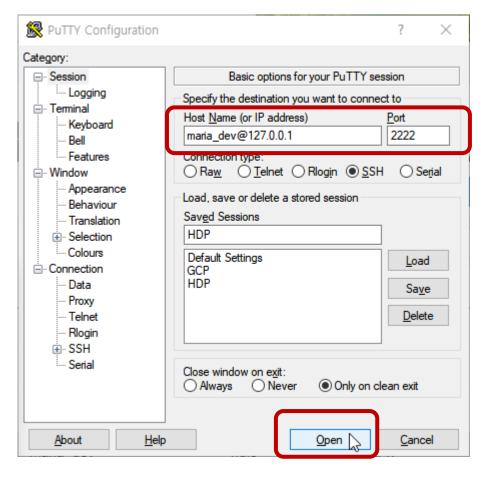


#### https://www.putty.org/





#### putty 실행



#### hadoop fs -ls

hadoop fs -mkdir ml-100k

```
maria dev@sandbox-hdp:~
  Using username "maria dev".
  maria dev@127.0.0.1's password:
Last login: Sat Jun 5 15:56:50 2021 from 172.18.0.3
[maria dev@sandbox-hdp ~]$ hadoop fs -ls
Found 2 items
drwxr-xr-x - maria dev hdfs
                                    0 2021-06-05 15:57 .Trash
drwxr-xr-x - maria dev hdfs
                                    0 2021-06-05 11:44 hive
[maria dev@sandbox-hdp ~]$ hadoop fs -mkdir ml-100k
[maria dev@sandbox-hdp ~]$ hadoop fs -ls
Found 3 items
drwxr-xr-x - maria dev hdfs
                                    0 2021-06-05 15:57 .Trash
drwxr-xr-x - maria_dev hdfs
                                    0 2021-06-05 11:44 hive
drwxr-xr-x - maria dev hdfs
                                    0 2021-06-05 15:59 ml-100k
[maria dev@sandbox-hdp ~]$ ls
[maria dev@sandbox-hdp ~]$ pwd
/home/maria dev
[maria dev@sandbox-hdp ~]$
```

wget https://github.com/kgpark88/bigdata/raw/main/ml-100k/u.data

ls

```
maria_dev@sandbox-hdp:~
[maria dev@sandbox-hdp ~]$ wget https://github.com/kgpark88/bigdata/raw/main/ml-100k/u.data
 -2021-06-05 16:12:19-- https://github.com/kgpark88/bigdata/raw/main/ml-100k/u.data
Resolving github.com (github.com) ... 15.164.81.167
Connecting to github.com (github.com) | 15.164.81.167 | :443... connected.
HTTP request sent, awaiting response... 302 Found
Location: https://raw.githubusercontent.com/kgpark88/bigdata/main/ml-100k/u.data [following]
 -2021-06-05 16:12:19-- https://raw.githubusercontent.com/kgpark88/bigdata/main/ml-100k/u.data
Resolving raw.githubusercontent.com (raw.githubusercontent.com)... 185.199.108.133, 185.199.109.13
3, 185.199.111.133, ...
Connecting to raw.githubusercontent.com (raw.githubusercontent.com) | 185.199.108.133 | : 443... connec
ted.
HTTP request sent, awaiting response... 200 OK
Length: 1979173 (1.9M) [text/plain]
Saving to: 'u.data'
                                                                             8.33MB/s
                                                                                        in 0.2s
2021-06-05 16:12:19 (8.33 MB/s) - 'u.data' saved [1979173/1979173]
[maria dev@sandbox-hdp ~]$ ls
u.data
[maria dev@sandbox-hdp ~]$
```

hadoop fs -copyFromLocal u.data ml-100k/u.data hadoop fs -ls ml-100k hadoop fs -rm ml-100k/u.data hadoop fs -rmdir ml-100k hadoop fs -ls

```
maria_dev@sandbox-hdp:~
[maria dev@sandbox-hdp ~]$ hadoop fs -copyFromLocal u.data ml-100k/u.data
[maria dev@sandbox-hdp ~]$ hadoop fs -ls ml-100k
Found 1 items
rw-r--r-- 1 maria dev hdfs 1979173 2021-06-05 16:13 ml-100k/u.data
[maria dev@sandbox-hdp ~]$ hadoop fs -rm ml-100k/u.data
21/06/05 16:15:19 INFO fs.TrashPolicyDefault: Moved: 'hdfs://sandbox-hdp.hortonworks.com:8020/user
maria dev/ml-100k/u.data' to trash at: hdfs://sandbox-hdp.hortonworks.com:8020/user/maria dev/.Tr/
ash/Current/user/maria dev/ml-100k/u.data
[maria dev@sandbox-hdp ~]$ hadoop fs -rmdir ml-100k
[maria dev@sandbox-hdp ~]$ hadoop fs -ls
Found 2 items

    maria dev hdfs

                             0 2021-06-05 16:15 .Trash
drwxr-xr-x

    maria dev hdfs

drwxr-xr-x
                                      0 2021-06-05 11:44 hive
[maria dev@sandbox-hdp ~]$
```

#### hadoop fs

```
maria_dev@sandbox-hdp:~
[maria dev@sandbox-hdp ~]$ hadoop fs
Usage: hadoop fs [generic options]
        [-appendToFile <localsrc> ... <dst>]
        [-cat [-ignoreCrc] <src> ...]
        [-checksum <src> ...]
        [-chgrp [-R] GROUP PATH...]
        [-chmod [-R] <MODE[,MODE]... | OCTALMODE> PATH...]
        [-chown [-R] [OWNER][:[GROUP]] PATH...]
        [-copyFromLocal [-f] [-p] [-l] <localsrc> ... <dst>]
        [-copyToLocal [-p] [-ignoreCrc] [-crc] <src> ... <localdst>]
        [-count [-q] [-h] [-v] [-t (<storage type>]] [-u] <path> ...]
        [-cp [-f] [-p | -p[topax]] <src> ... <dst>]
        [-createSnapshot <snapshotDir> [<snapshotName>]]
        [-deleteSnapshot <snapshotDir> <snapshotName>]
        [-df [-h] [<path> ...]]
        [-du [-s] [-h] <path> ...]
        [-expunge]
        [-find <path> ... <expression> ...]
        [-get [-p] [-ignoreCrc] [-crc] <src> ... <localdst>]
        [-getfacl [-R] <path>]
        [-getfattr [-R] {-n name | -d} [-e en] <path>]
        [-getmerge [-nl] <src> <localdst>
        [-help [cmd ...]]
        [-ls [-C] [-d] [-h] [-q] [-R] [-t] [-S] [-r] [-u] [<path> ...]]
        [-mkdir [-p] <path> ...]
        [-moveFromLocal <localsrc> ... <dst>]
        [-moveToLocal <src> <localdst>]
```

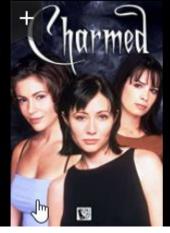
## MapReduce

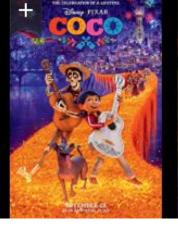
Mapper는 데이터를 변환(transform)하고 Reducer는 데이터를 집계(aggregate) 하는 것입니다.

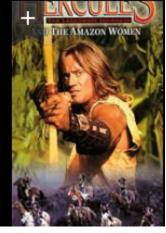
MovieLens 데이터셋에서 각 사용자는 몇 개의 영화에 대해 평점을 매겼을까요?



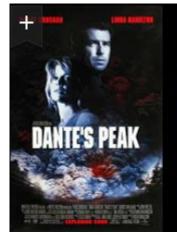










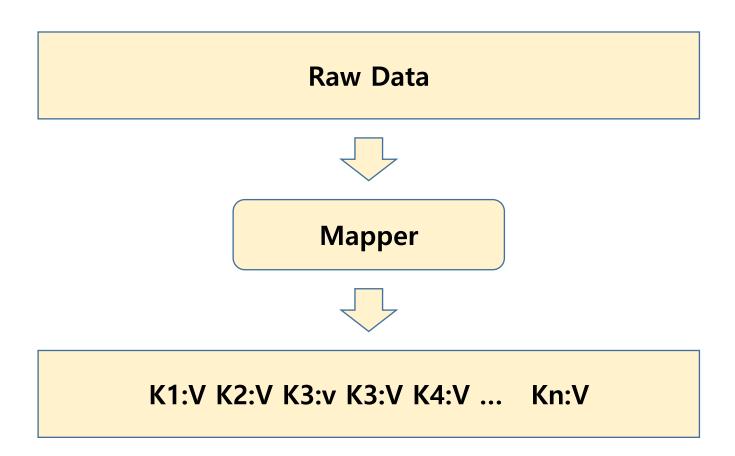






## Mapper Function

Mapper는 raw 소스 데이터를 key/value pair로 변환합니다.



## Mapper on Movie Data

#### **Extract and Organize What we care about**

USER ID	MOVIE ID	RATING	TIMESTAMP
196	242	3	881250949
186	302	3	891717742
196	377	1	878887116
244	51	2	880606923
166	346	1	886397596
186	474	4	884182806
186	265	2	881171488
	-		



Mapper

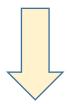


196:242 186:302 196:377 244:51 166:346 186:274 186:265

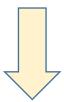
## Sort and Shuffle Mapper Data

#### MapReduce Sorts and Groups the Mapped Data

196:242 186:302 196:377 244:51 166:346 186:274 186:265



**Shuffle & Sort** 

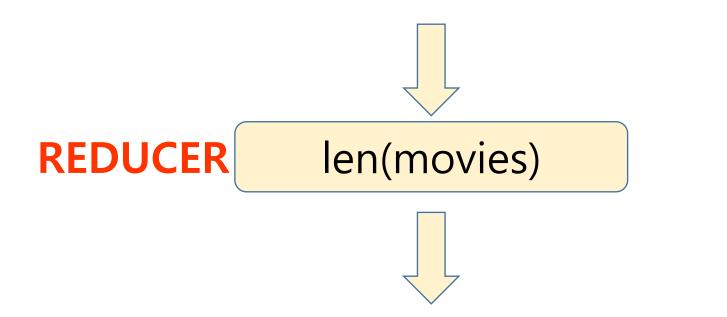


166:346 186:302,274,265 196:242,377 244:51

## Reducer Process Each Key Value

The REDUCER Processes Each Key's Values

166:346 186:302,274,265 196:242,377 244:51

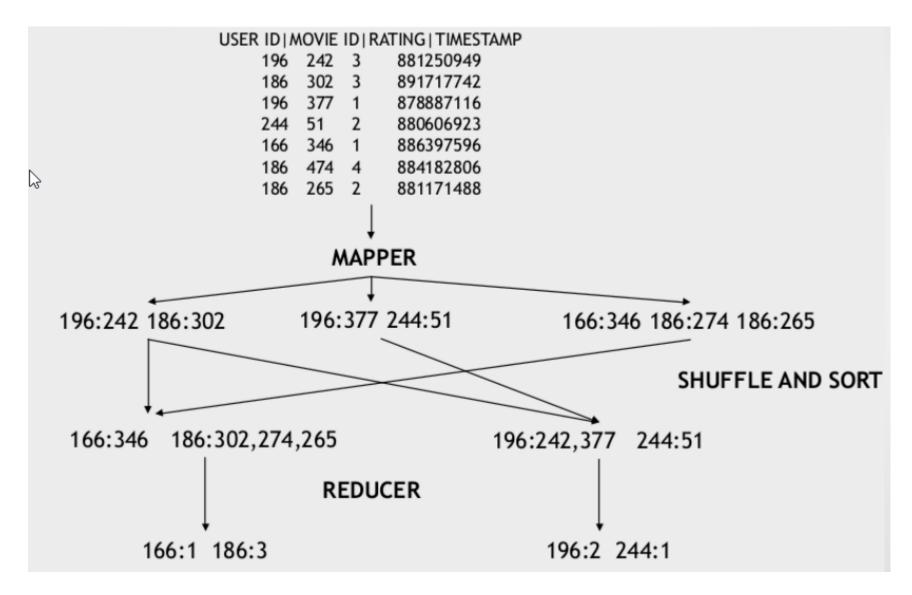


166:1 186:3 196:2 244:1

## Mapper and Reduce

```
USER ID | MOVIE ID | RATING | TIMESTAMP
                196 242 3
                            881250949
                186
                   302 3
                            891717742
                   377 1 878887116
                244 51 2
                          880606923
                166 346 1 886397596
                186 474 4 884182806
                186 265 2
                          881171488
                      MAPPER
196:242 186:302 196:377 244:51 166:346 186:274 186:265
                SHUFFLE AND SORT
              186:302,274,265 196:242,377 244:51
      166:346
                      REDUCER
              166:1 186:3 196:2 244:1
```

## Mapper & Reducer in Cluster



## MapReduce Program (참고)

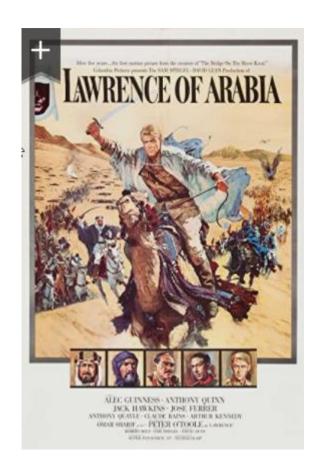
```
RatingsBreakdown.py
    from mrjob.job import MRJob
    from mrjob.step import MRStep
    class RatingsBreakdown(MRJob):
        def steps(self):
            return
                MRStep(mapper=self.mapper_get_ratings,
                        reducer=self.reducer count ratings)
        def mapper_get_ratings(self, , line):
11
            (userID, movieID, rating, timestamp) = line.split('\t')
12
13
            yield rating, 1
14
        def reducer_count_ratings(self, key, values):
15
            yield key, sum(values)
16
17
   <u>if name == '_main_':</u>
        RatingsBreakdown.run()
```

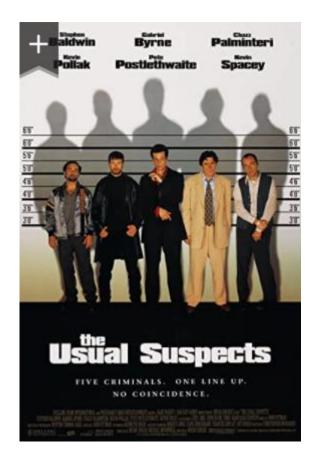
#### ■ 실행방법 참고

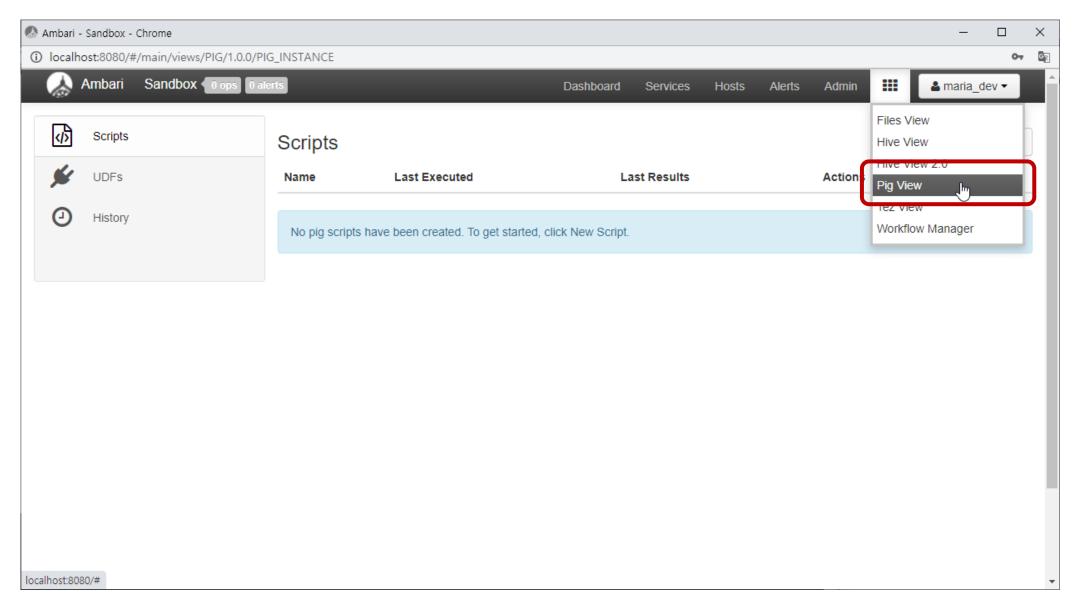
http://www.nitesh-research.com/wp-content/uploads/nitesh-hadoop-12-09-2020.pdf

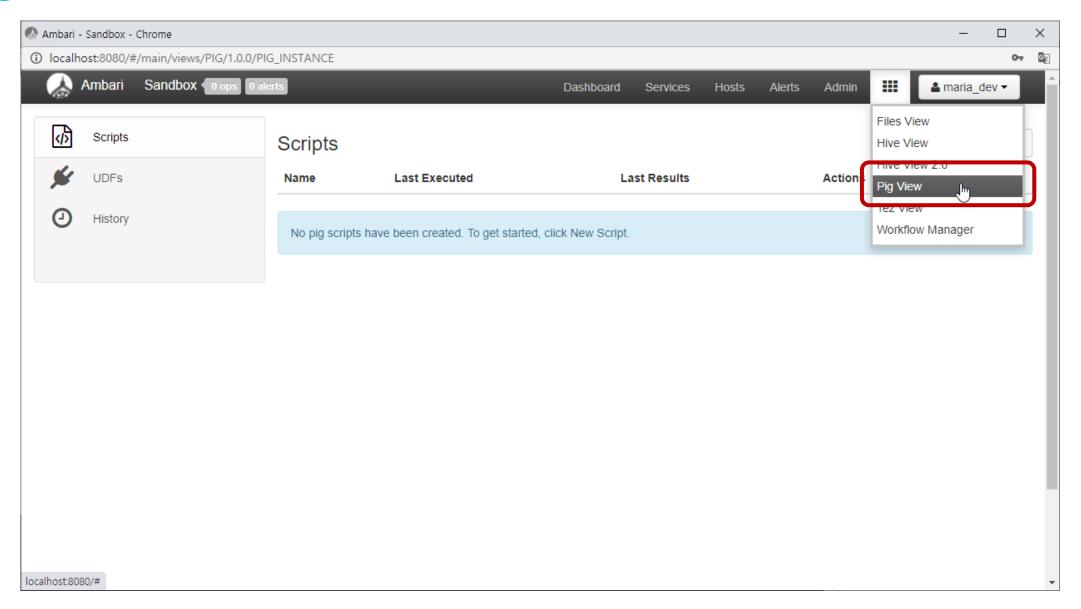
#### Find the oldest 5-star movies

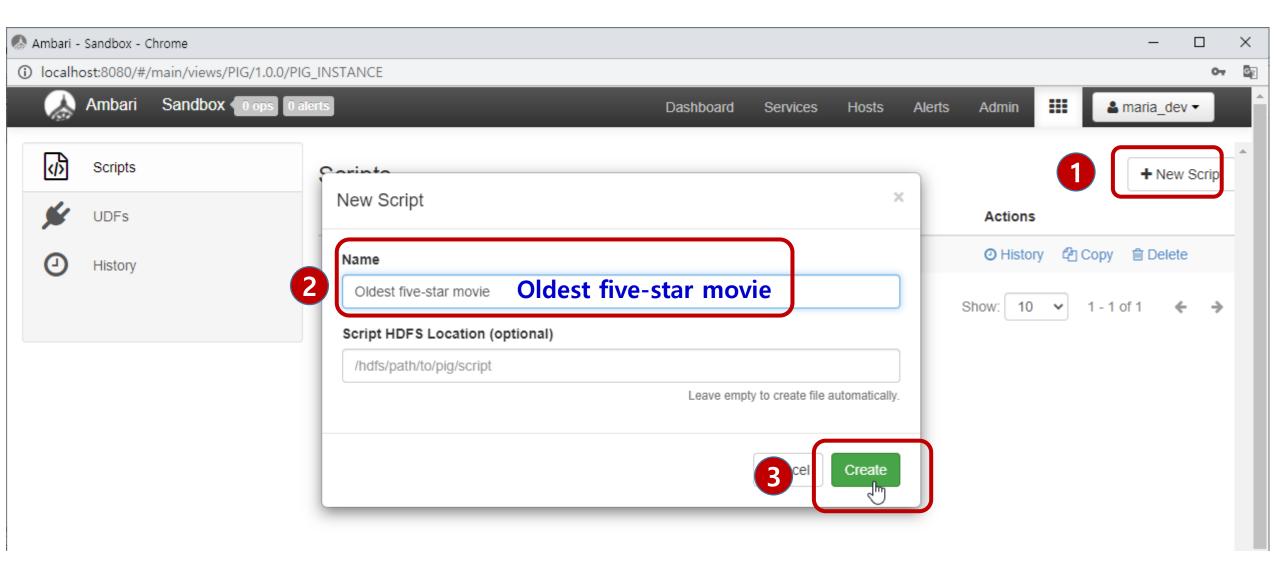


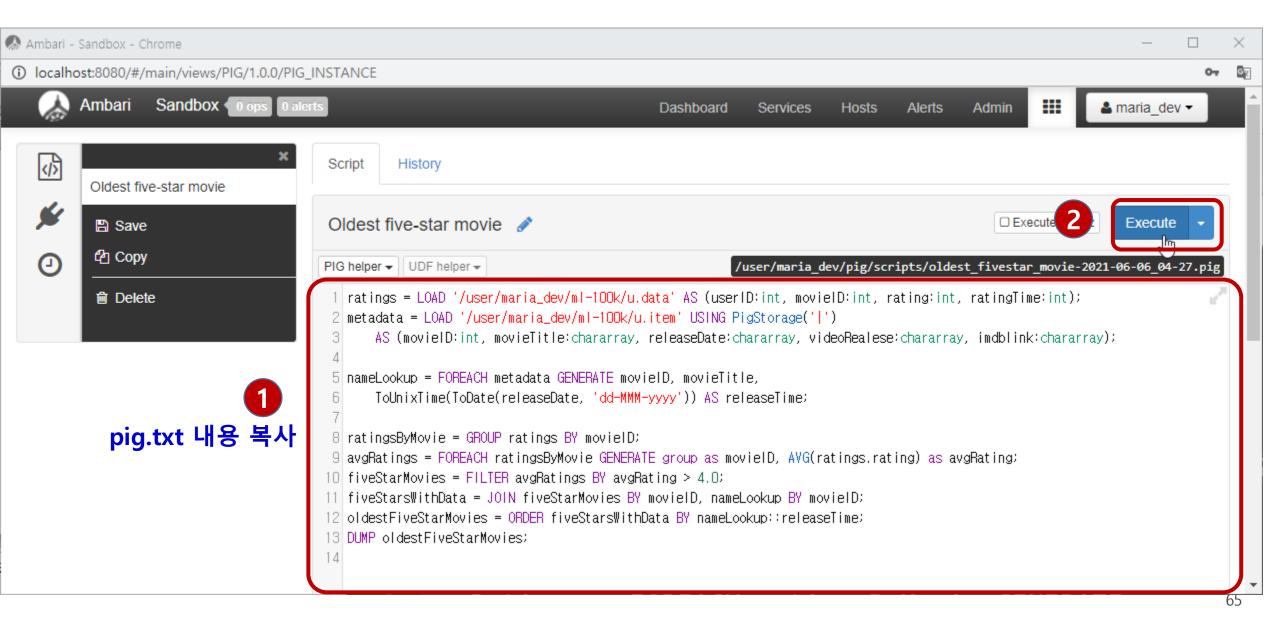


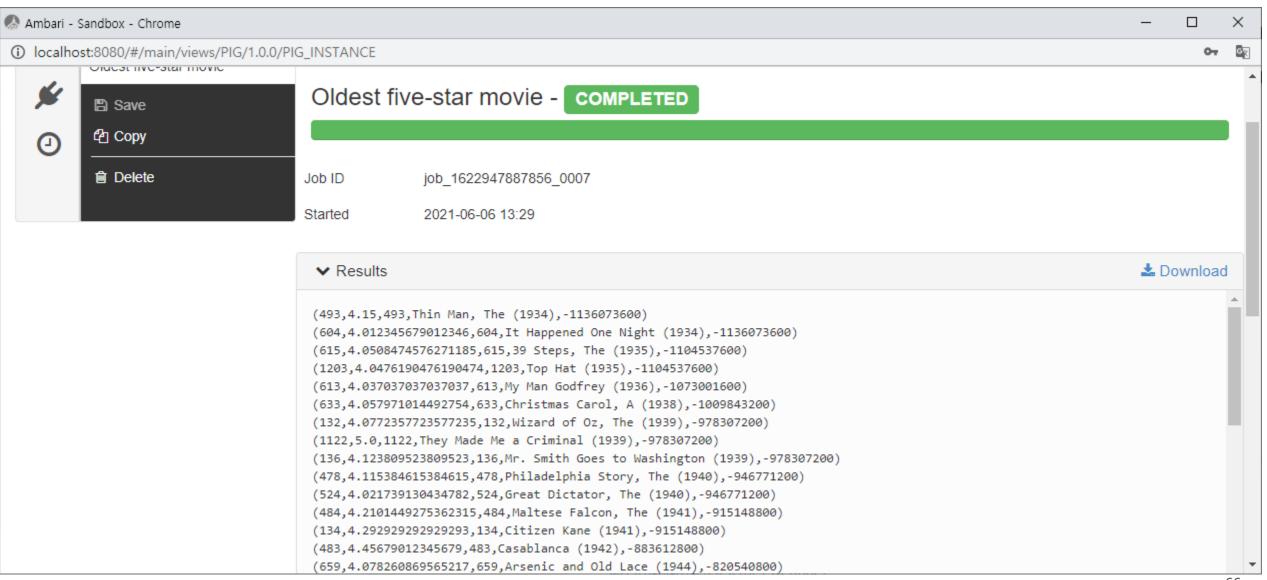












# Thank you