빅데이터 프로세싱 엔진 Spark

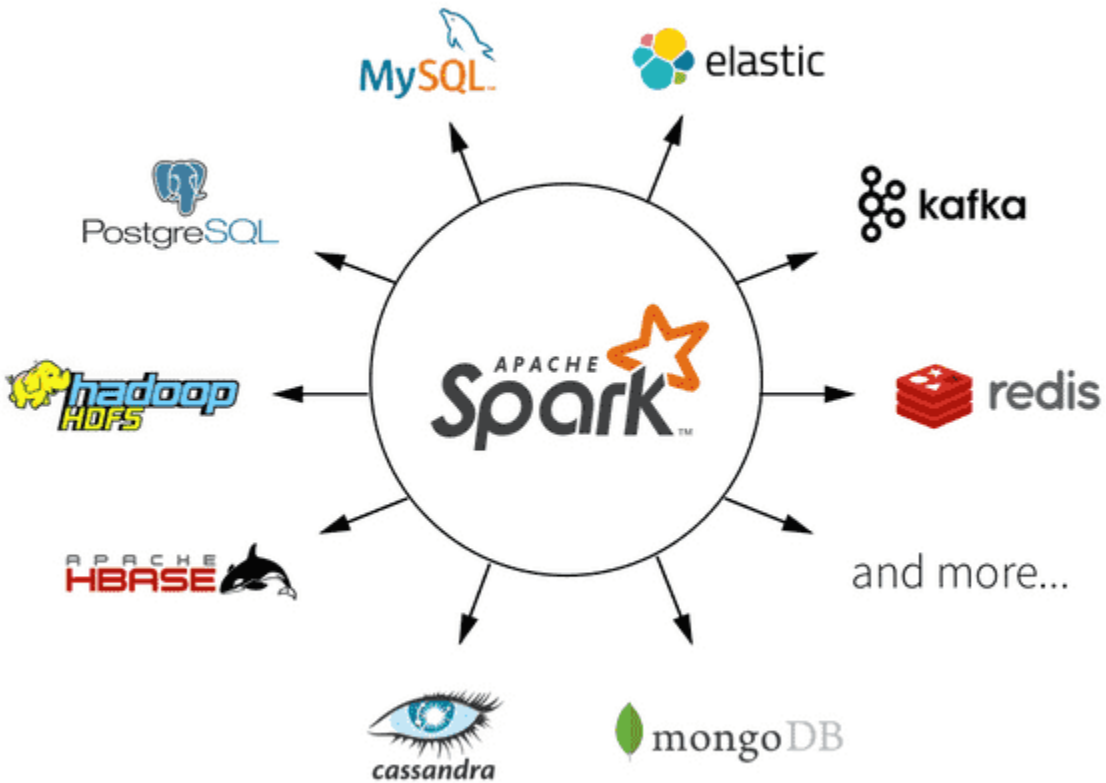

박경규

Spark

https://spark.apache.org/

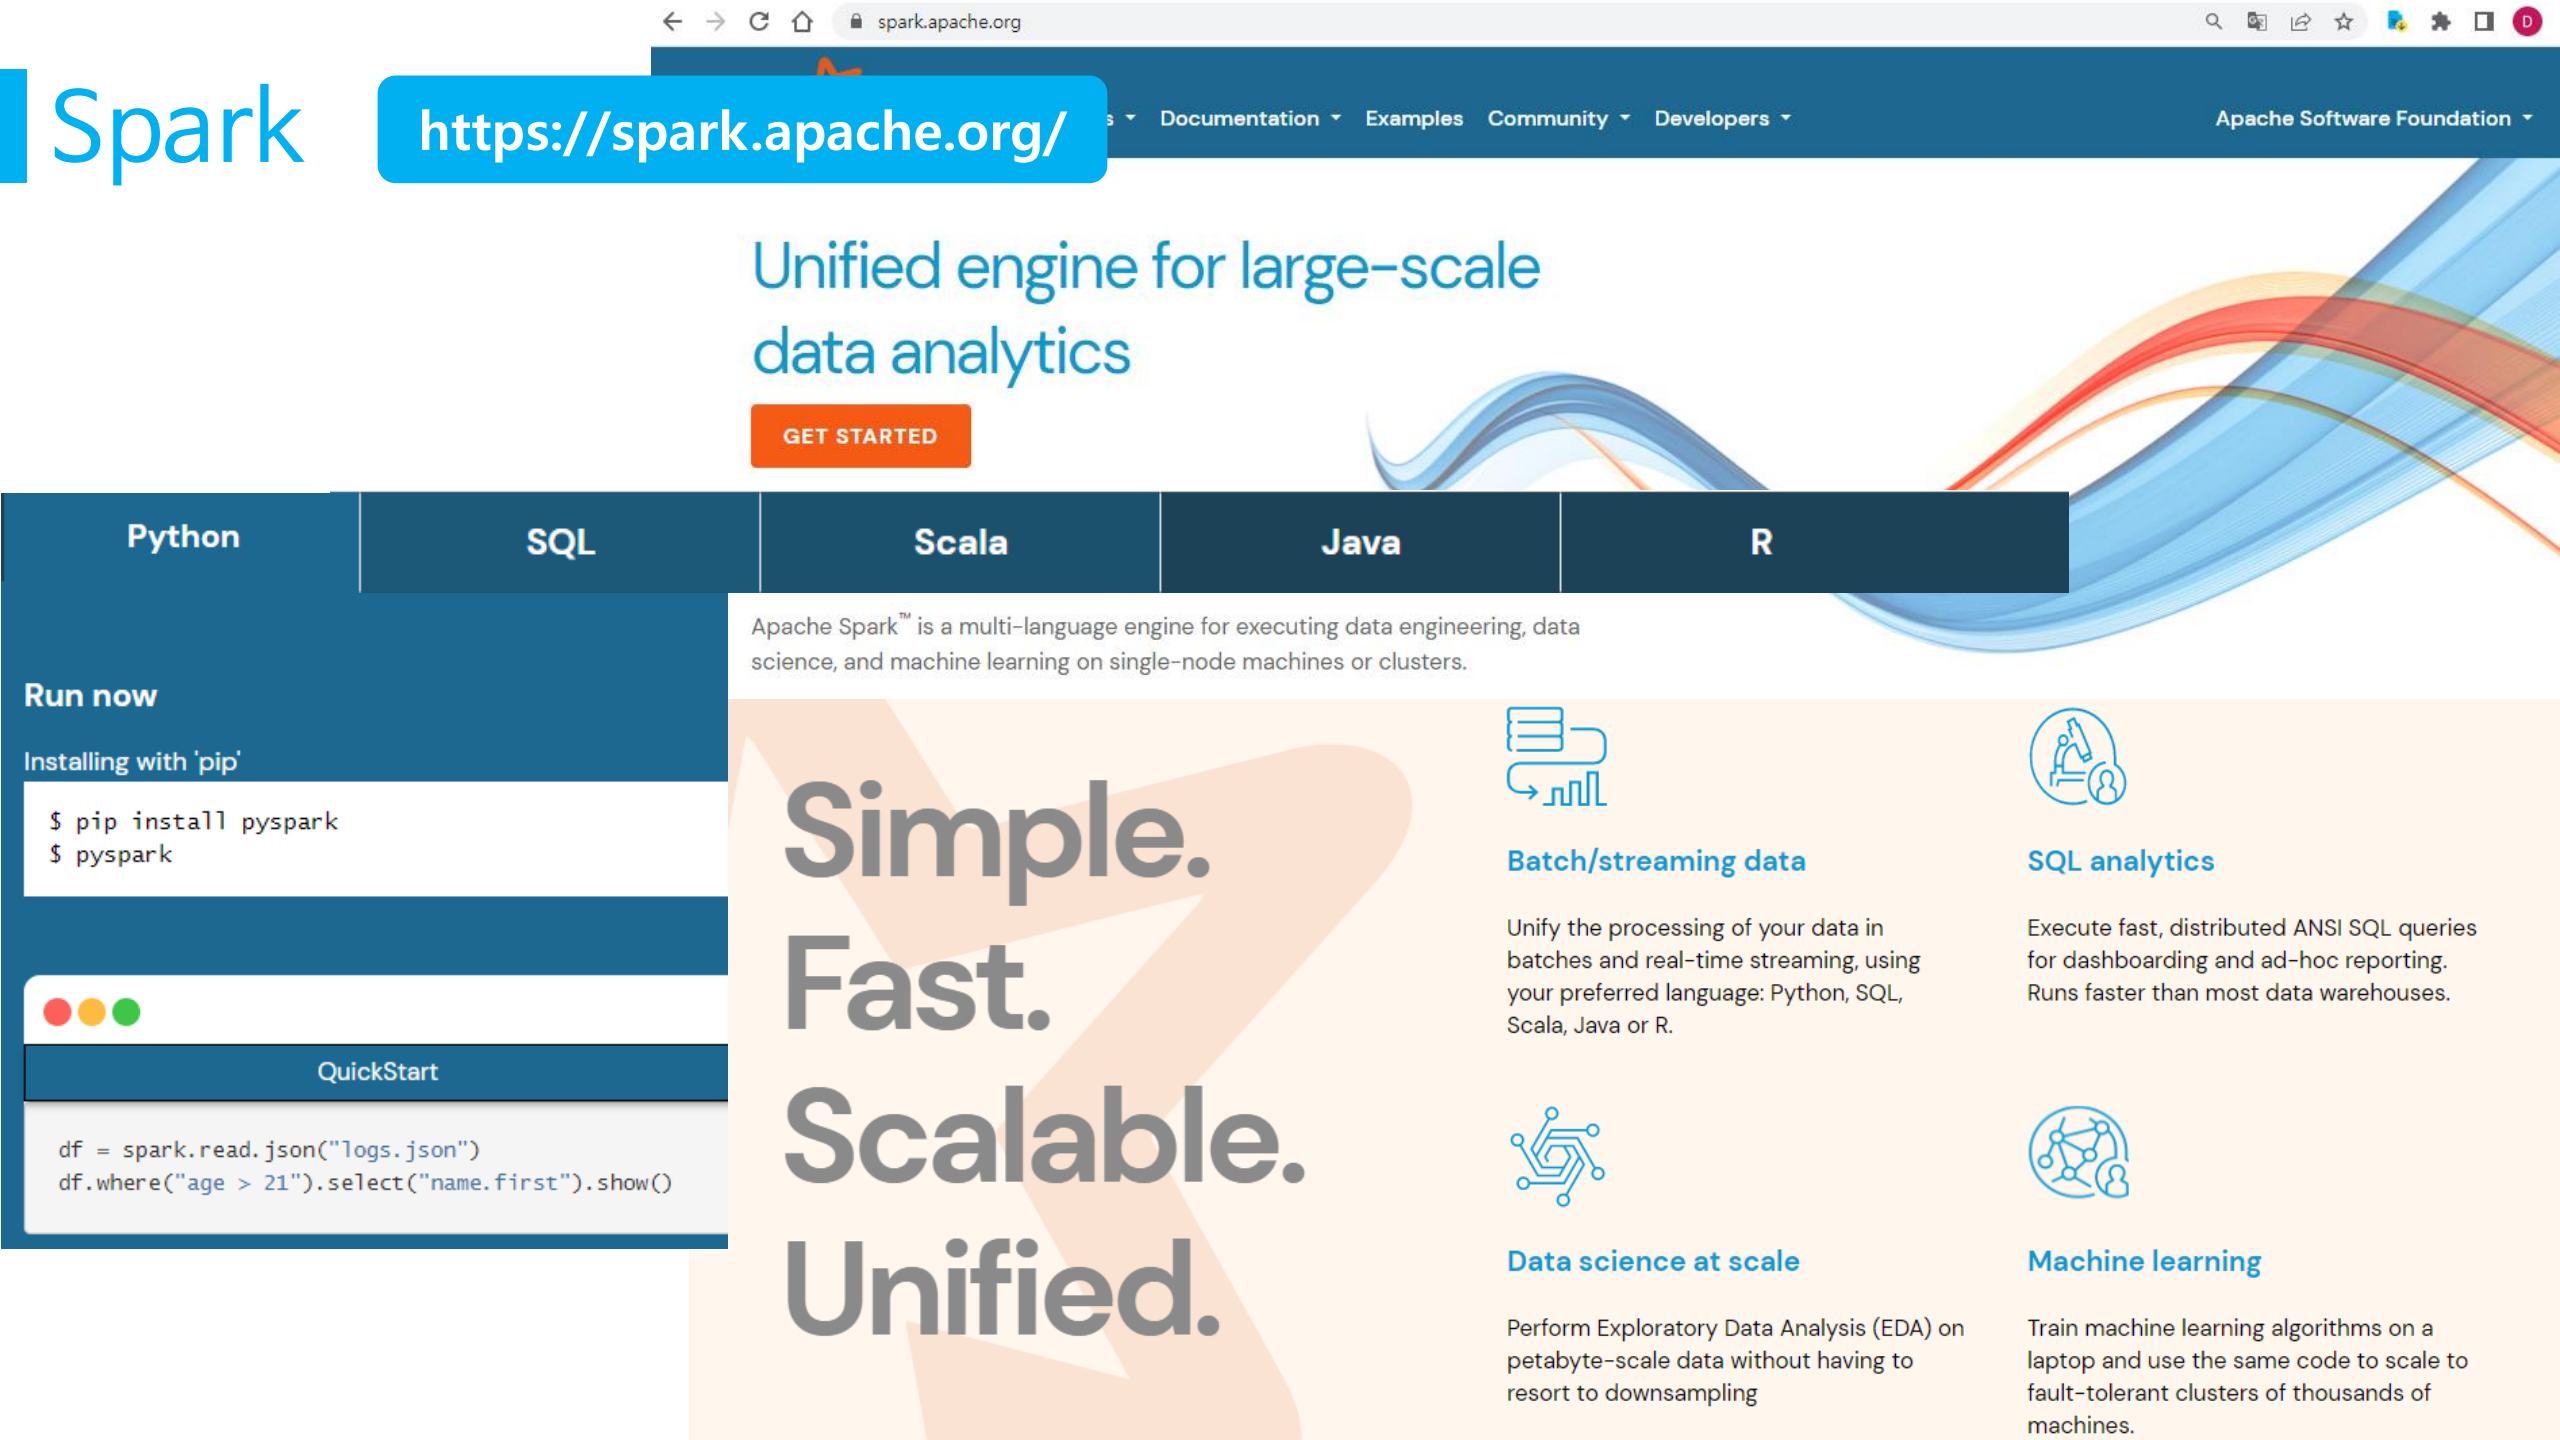

Spark 아키텍처

- 인메모리 기반의 대용량 데이터 고속 처리 엔진으로 범용 분산 클러스터 컴퓨팅 프레임워크입니다.
- UC Berkeley의 AMPLab에서 만들었으며, 사용 편의성과 속도로 인기가 높습니다.
- Spark를 MapReduce의 flexible alternative 으로 생각할 수 있습니다.
- Spark는 Cassandra, AWS S3, HDFS 등 다양한 형식으로 저장된 데이터를 사용할 수 있습니다.
- Apache Spark는 구조화된 데이터를 처리하기 위한 **Spark SQL**과 머신러닝을 위한 **ML Lib**, 그래프 처리를 위한 **Graph X**, 실시간 처리와 방대한 연산을 위한 **Structured Streaming** 도구를 제공합니다.
- Python, SQL, Scala, Java, R 과 같은 다양한 프로그래밍 언어 API를 제공한다.

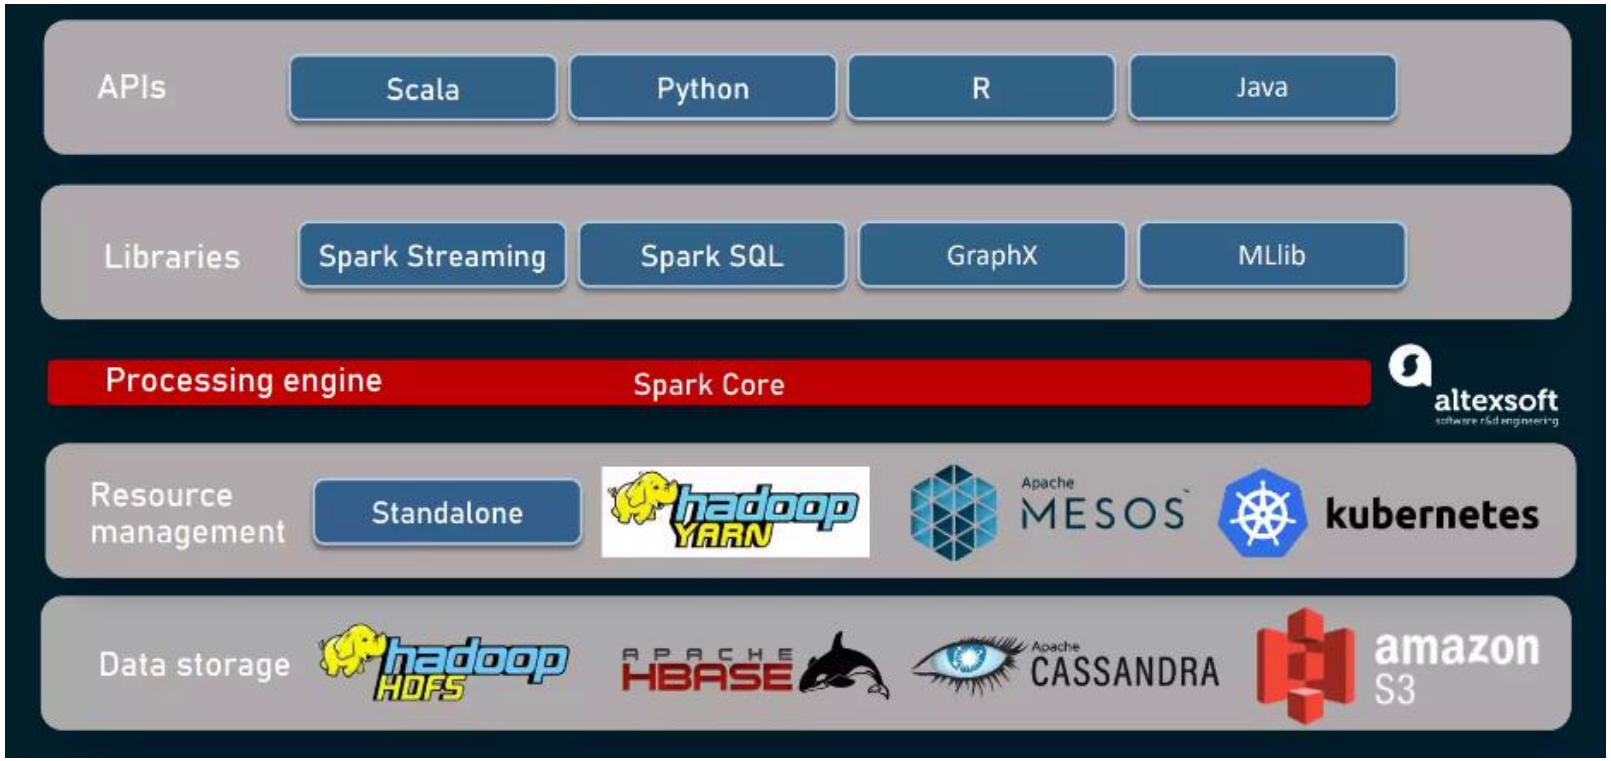

https://www.altexsoft.com/blog/hadoop-vs-spark/

Hadoop vs Spark

- Hadoop MapReduce는 각 map, reduce 이후에 대부분의 데이터를 디스크(HDFS)에 저장합니다.
- Spark는 각 변환 후 대부분의 데이터를 메모리에 보관합니다 .
- Spark는 인메모리(In-Memory) 기반의 처리로 하둡의 맵리듀스에 비해서 100배 빠른 속도를 제공하고, 머신러닝, 그래프처리 등 빅데이터 분석을 위한 통합 컴포넌트를 제공합니다.

	Hadoop	Spark
What is it?	Open-source framework for distributed data storage and processing	Open-source framework for in-memory distributed data processing and app development
Initial release	2006	2014
Supported languages	Java	Scala, Java, Python, R
Processing methods	Batch processing, using hard discs to read/write data	Batch and micro-batch processing in RAM
Built-in capabilities	✓ File system (HDFS) ✓ Resource management (Yarn) ✓ Processing engine (MapReduce)	✓ Processing engine (Spark Core) ✓ Near real-time processing (Spark Streaming) ✓ Structured data processing (Spark SQL) ✓ Graph data management (GraphX) ✓ ML library (MLlib)

	Hadoop	Spark
Best fit for	Delay-tolerant processing tasks, involving huge datasets	Almost instant processing of live data and quick analytics app development
Real-life use cases	✓ Enterprise archived data processing ✓ Sentiment analysis ✓ Predictive maintenance ✓ Log files analysis	✓ Fraud detection ✓ Telematics analytics ✓ User behavior analysis ✓ Near real-time recommender systems ✓ Stock market trends prediction ✓ Risk management

https://www.altexsoft.com/blog/hadoop-vs-spark/

버전별 특징

Spark V1

- RDD를 이용한 인메모리 처리로 기존 방식 대비 빠른 속도로 처리가 가능함
- V1.3에서 데이터프레임 추가 : 프로젝트 텅스텐
- V1.6에서 데이터셋 추가 : 데이터 타입체크, 인코더, 카탈리스트 옵티마이저 지원

Spark V2

- 2016년 RDD의 기능을 개선한 데이터프레임과 데이터셋을 통합한 V2가 발표 되었습니다.
- 데이터를 스키마 형태로 추상화 하여 제공
- 쿼리 최적화 기능 추가

Spark V3

- 파이썬3, 스칼라 2.12, JDK 11 지원
- 딥러닝 지원 강화 : GPU 지원 추가
- 바이너리 파일 지원
- 쿠버네티스 지원 강화
- 다이나믹 파티션 프루닝(DPP) 지원하여 SQL 지원 강화

https://wikidocs.net/80412

RDD (Resilient Distributed Dataset)

- Spark에서 사용되는 가장 기본적인 데이터 객체입니다.
- Spark에서 데이터는 클러스터 메모리에 분산되어 Partition 단위로 분산 저장됩니다.
- Lineage(RDD를 만드는 일련의 단계)를 기록하여 노드의 장애/실패 발생 시 데이터를 재구성할 수 있습니다.
- RDD는 외부 데이터를 읽어서 처리하거나, 자체적으로 컬렉션 데이터를 생성하여 처리할 수 있습니다.

■ RDD 주요 특성(feature)

- Distributed Collection of Data
- Fault-tolerant
- Parallel operation – partitioned
- Ability to use many data sources

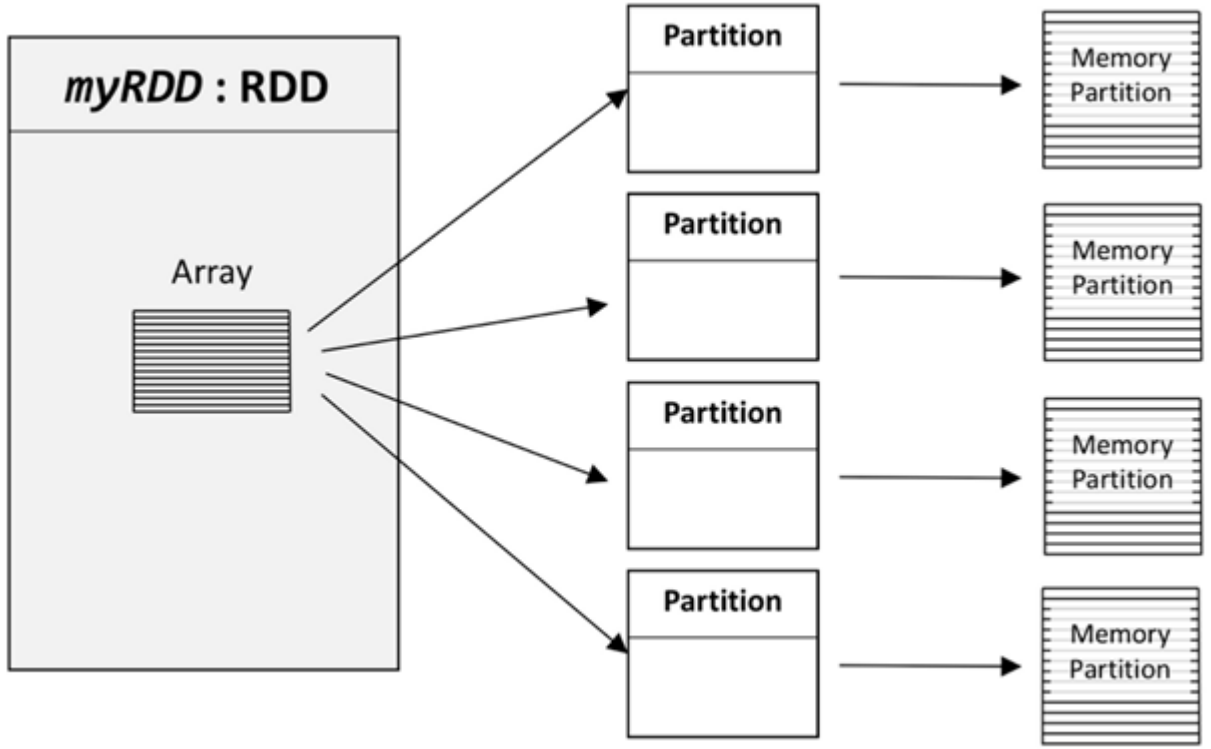

RDD Operation

Transformation

- Spark의 동작 중에서 데이터를 처리하는 명령
- map, filter, flatMap, join 등

Action

- Transformation의 결과를 저장하는 명령
- count, collect, reduce, save 등

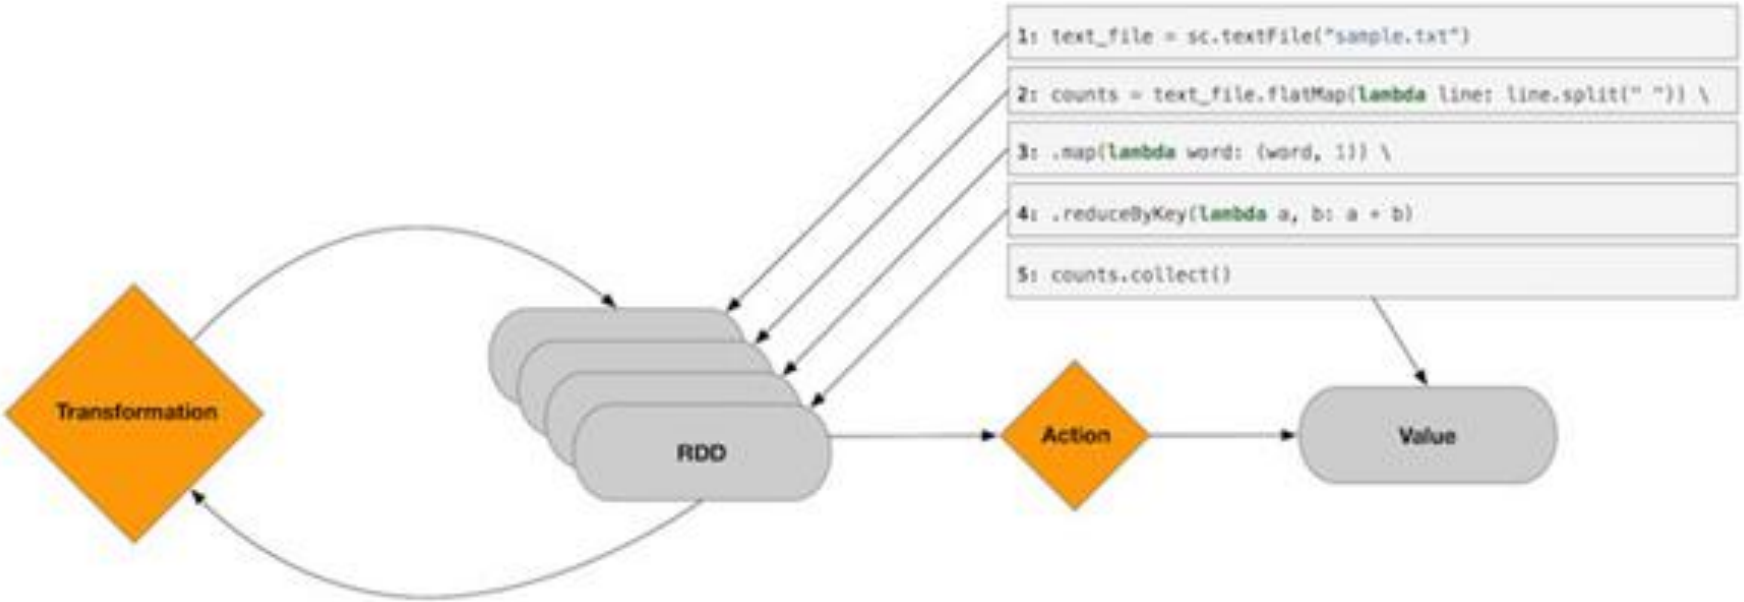

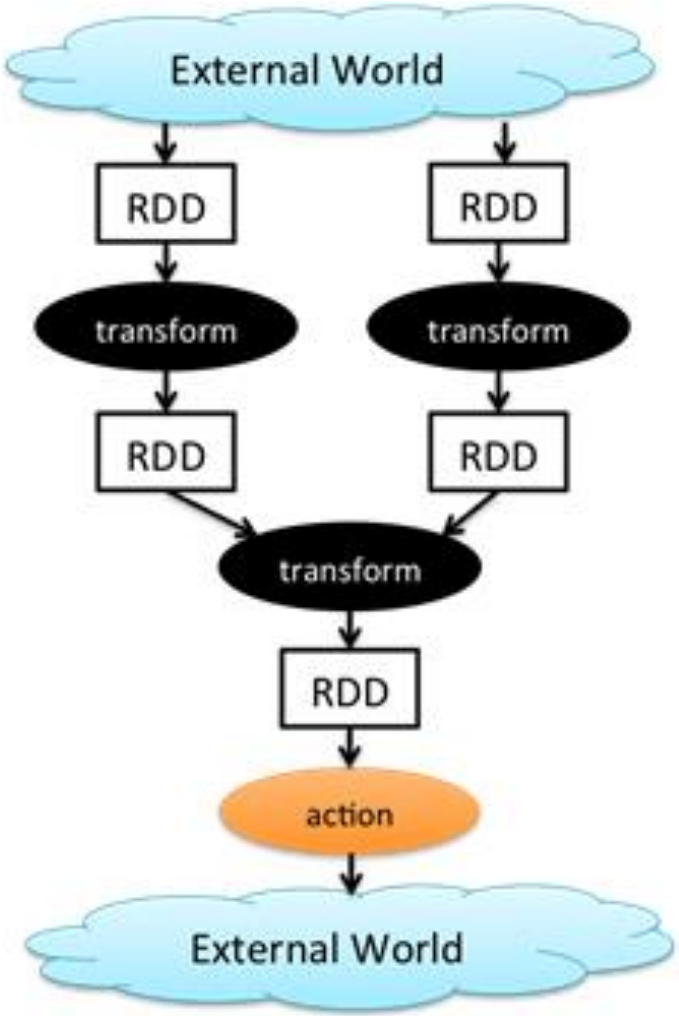

RDD

- Spark 1 에서는 RDD를 주로 사용하였지만, Spark 2에서는 DataFrame(구조적 데이터 형태)을 사용

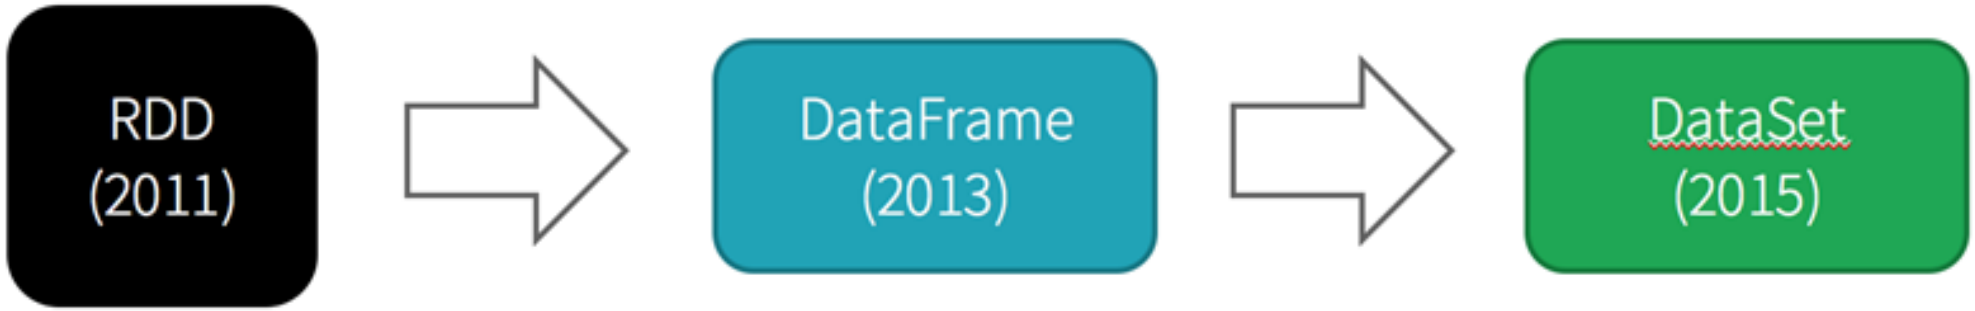

Distribute collection of JVM objects

Functional Operators (map, filter, etc.)

Distribute collection of Row objects

Expression-based operations and UDFs

Logical plans and optimizer

Fast/efficient internal representations

Internally rows, externally JVM objects

Almost the "Best of both worlds": **type safe + fast**

But slower than DF
Not as good for interactive analysis, especially Python

databricks

Crerating RDD

- nums = parallelize([1, 2, 3, 4])
- sc.textFile("file:///opt/spark/README.md") or s3n:// . hdfs://
- hiveCtx = HiveContext(sc) rows = hiveCtx.sql("SELECT name, age FROM users")
- Can also create from:
  - JDBC
  - Cassandra
  - Hbase
  - Elasticsearch
  - JSON, CSV, sequence files, object files, various compressed formats

Transforming RDD

- map
- flatmap
- filter
- distinct
- sample
- union, intersection, subtract, cartesian

map example

```
rdd = sc.parallelize([1, 2, 3, 4])
quaredRDD = rdd.map(lambda x: x*3)

This yeilds 1, 4, 9, 16
```

RDD actions

- collect
- count
- countByValue
- take
- top
- reduce
- … and more …

Spark 애플리케이션 구조

- Spark는 작업을 관리하는 Driver 프로그램과 작업이 실행되는 노드를 관리하는 Cluster Manager로 구성되어 있습니다.
- Spark 애플리케이션은 작업을 관장하는 Driver와 실제 작업이 동작하는 Executor 로 구성됩니다.
- Driver는 SparkContext 객체를 생성하여 Cluster Manager와 통신하면서 클러스터의 자원 관리를 지원하고, 애플리케이션의 라이프 사이클을 관리합니다.
- Executor은 사용자가 만든 SparkContext(일종의 앱)를 위해 데이터를 저장하거나 연산을 실행하는 프로세스입니다.
- Spark는 프로그래밍 언어(Python, R, Java)로 코드를 작성한 파일을 각 클러스터 내부에 있는 Executor들에게 전달합니다.

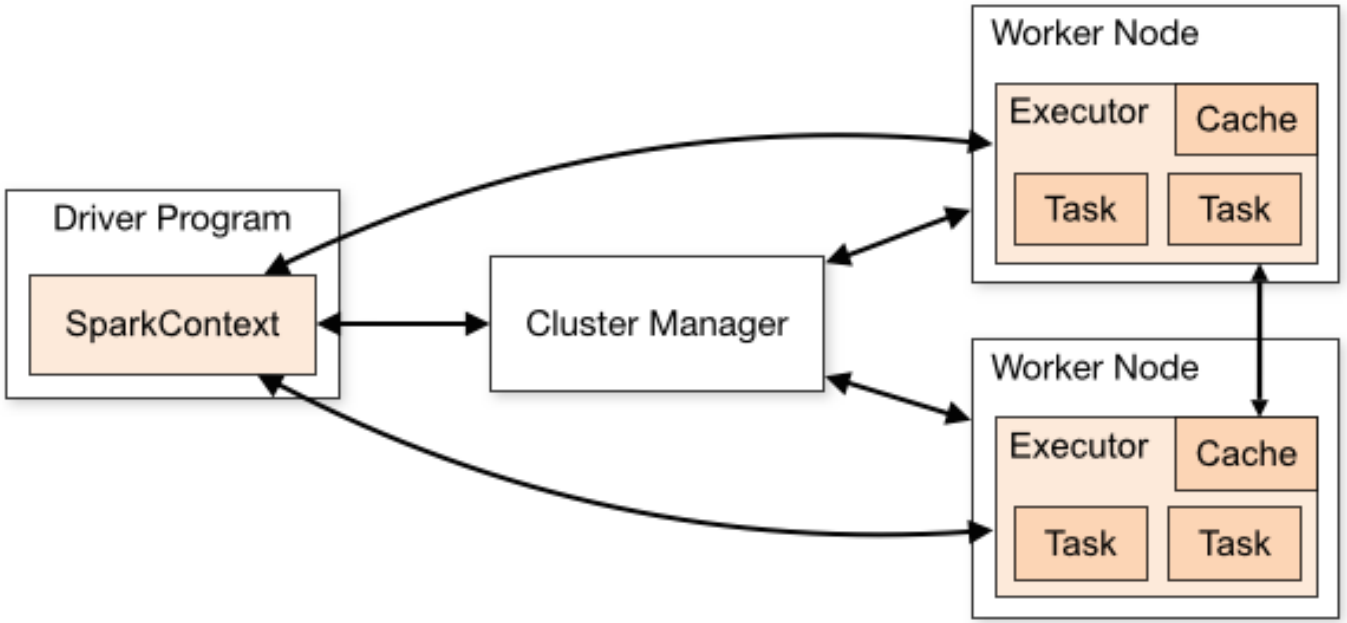

https://wikidocs.net/26630

Spark 애플리케이션

드라이버와 익스큐터 프로세스로 실행되는 프로그램으로
클러스터 매니저가 스파크 애플리케이션의 리소스를 효율적으로 배분하게 됩니다.

Driver

- Spark Driver는 스파크 애플리케이션을 실행하는 프로세스입니다.
- main 함수를 실행하고 SparkContext 객체를 생성합니다.
- Spark 애플리케이션의 라이프 사이클을 관리하고, 사용자로 부터 입력을 받아서 애플리케이션에 전달합니다. 작업 처리 결과를 사용자에게 알려줍니다.
- Driver는 실행 시점에 디플로이 모드를 클라이언트 모드와 클러스터 모드로 설정할 수 있습니다.

Executor

- 태스크(Task) 실행을 담당하는 에이전트로 실제 작업을 진행하는 프로세스입니다.
- YARN의 컨테이너 라고 볼 수 있습니다.
- Executor는 Task 단위로 작업을 실행하고 결과를 드라이버에 알려줍니다.
- Executor 가 동작 중 오류가 발생하면 다시 재작업을 진행합니다.

Task

- Executor에서 실행되는 실제 작업(Task)입니다.
- Executor의 Cache를 공유하여 작업의 속도를 높일 수 있습니다.

https://wikidocs.net/26630

Spark Job 구성

스파크 애플리케이션의 작업은 Job, Stage, Task로 구성됩니다.

- Job : 스파크 애플리케이션으로 제출된 작업입니다.
- Stage : Job을 작업의 단위에 따라 구분한 것이 스테이지입니다.
- Task : Executor에서 실행되는 실제 작업입니다.
  데이터를 읽거나, 필터링 하는 실제 작업을 처리합니다.

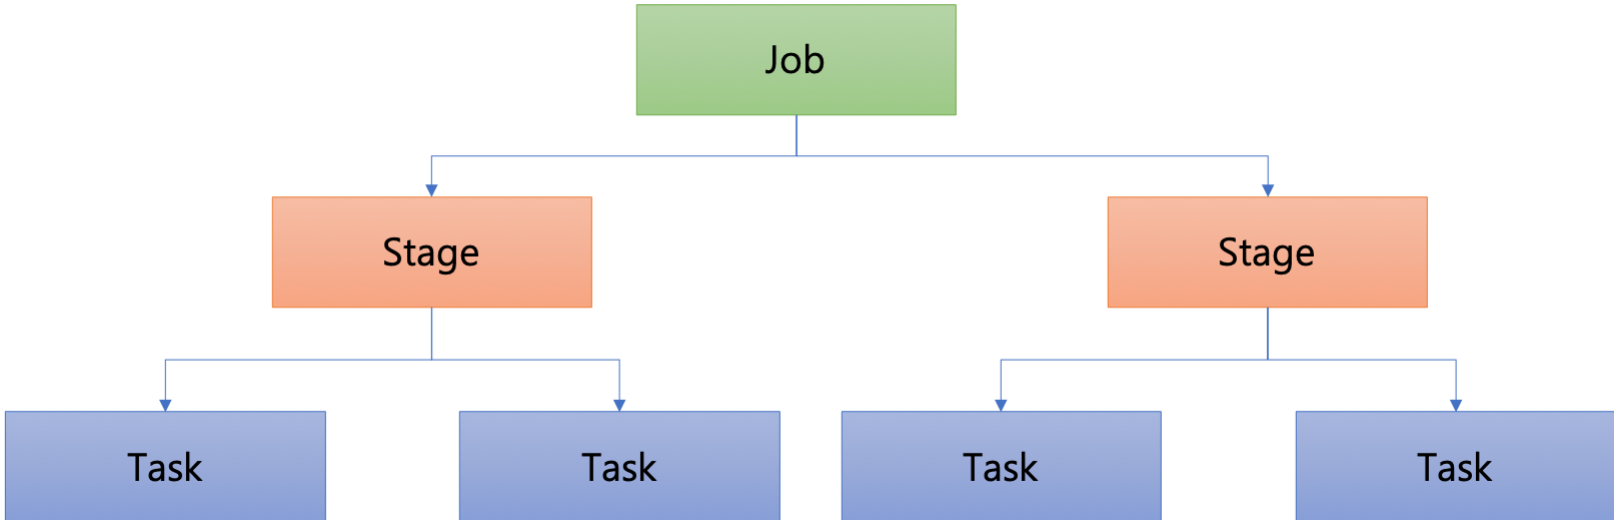

https://wikidocs.net/26630

클러스터 매니저

StandAlone

- 간단한 클러스터 매니저가 Spark에 포함되어있어 관리자는 클러스터를 쉽게 구성할 수 있습니다.
- 단일 머신에서 테스트를 위해 사용할 수 있습니다

Apache Mesos

- Hadoop의 MapReduce와 서비스 응용프로그램을 실행할 수 있는 일반적인 클러스터 관리자입니다.
- Spark와 다른 프레임워크 사이의 동적 구분과 Spark의 여러 인스턴스 사이의 확장 파티션 장점이 있습니다.

YARN

- YARN은 기존 MapReduce 중에서 클러스터의 리소스를 관리하는 부분만 가져와서 다른 서비스에서도 사용 가능 하도록 구성한 시스템입니다.
- YARN 시스템은 기존 MapReduce 보다는 기능적으로는 간단하지만, 범용적인 분산 리소스 관리 시스템이 되어야 했기 때문에 MapReduce의 클러스터 관리체계 보다 더 복잡하고 다양한 기능을 제공하고 있습니다.
- YARN은 핵심 구성 요소는 Resource Manager와 Node Manager입니다.
- 참조 : https://www.popit.kr/what-is-hadoop-yarn/

Spark DataFrame

Spark DataFrame은 Spark의 Machine Learning을 사용하는 표준 방법입니다,

- Spark DataFrame는 column과 row 형식으로 데이터를 보유합니다.
- 각 column은 속성(feature)을 나타내며, 각 행은 개별 데이터 포인터 입니다.
- RDD syntax는 Spark 2에서 훨씬 더 깔끔하고 작업하기 쉬운 DataFrame 구문으로 전환 되었습니다.
- Spark DataFrame은 다양한 소스의 데이터를 입력 및 출력 할 수 있습니다.
- DataFrame을 사용하여 데이터에 다양한 변환(transformation)을 적용 할 수 있습니다.

PySpark

https://spark.apache.org/docs/latest/api/python/

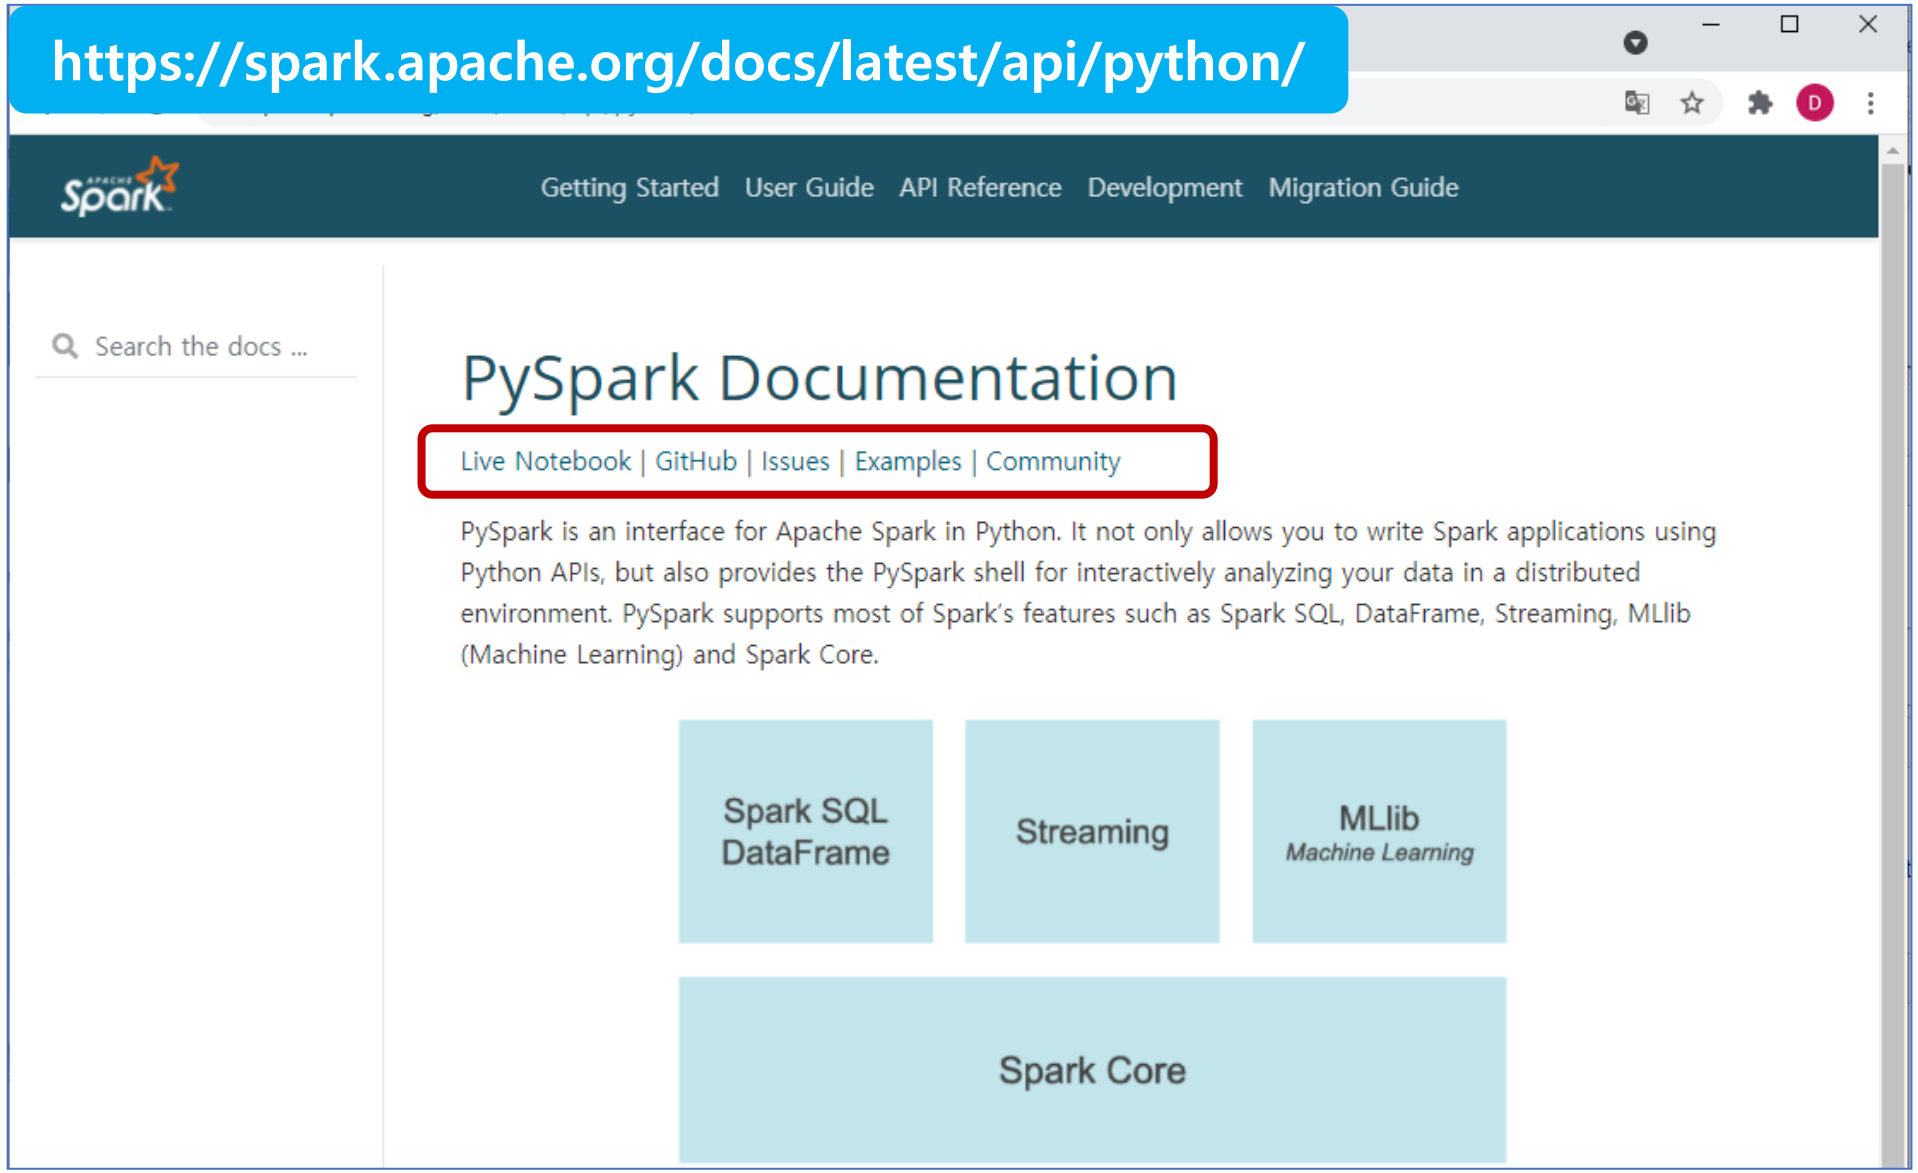

PySpark 실습(터미널 환경)

LowestRatedMovieSpark.py

Find the movie with the lowest average rating

```python
from pyspark import SparkConf, SparkContext

# This function just creates a Python "dictionary" we can later
# use to convert movie ID's to movie names while printing out
# the final results.
def loadMovieNames():
    movieNames = {}
    with open("ml-100k/u.item") as f:
        for line in f:
            fields = line.split('|')
            movieNames[int(fields[0])] = fields[1]
    return movieNames

# Take each line of u.data and convert it to (movieID, (rating, 1.0))
# This way we can then add up all the ratings for each movie, and
# the total number of ratings for each movie (which lets us compute the average)
def parseInput(line):
    fields = line.split()
    return (int(fields[1]), (float(fields[2]), 1.0))

if __name__ == "__main__":
    # The main script - create our SparkContext
    conf = SparkConf().setAppName("WorstMovies")
    sc = SparkContext(conf = conf)

```

LowestRatedMovieSpark.py

PySpark 실습(터미널 환경)

```
26      # Load up our movie ID -> movie name lookup table
27      movieNames = loadMovieNames()
28
29      # Load up the raw u.data file
30      lines = sc.textFile("hdfs:///user/maria_dev/ml-100k/u.data")
31
32      # Convert to (movieID, (rating, 1.0))
33      movieRatings = lines.map(parseInput)
34
35      # Reduce to (movieID, (sumOfRatings, totalRatings))
36      ratingTotalsAndCount = movieRatings.reduceByKey(lambda movie1, movie2: ( movie1[0] + movie2[0], movie1[1] + movie2[1] ) )
37
38      # Map to (movieID, averageRating)
39      averageRatings = ratingTotalsAndCount.mapValues(lambda totalAndCount : totalAndCount[0] / totalAndCount[1])
40
41      # Sort by average rating
42      sortedMovies = averageRatings.sortBy(lambda x: x[1])
43
44      # Take the top 10 results
45      results = sortedMovies.take(10)
46
47      # Print them out:
48      for result in results:
49          print(movieNames[result[0]], result[1])
50
```

PySpark 실습(터미널 환경)

putty 실행

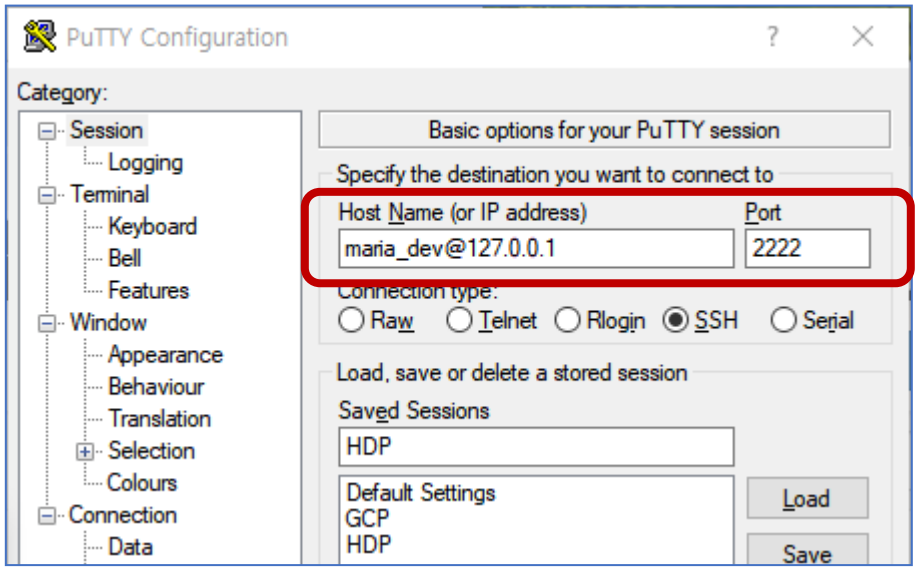

■ HDP 터미널에서 명령어 실행

mkdir ml-100k

cd ml-100k

wget https://github.com/kgpark88/bigdata/raw/main/ml-100k/u.item

cd ..

wget https://github.com/kgpark88/bigdata/raw/main/LowestRatedMovieSpark.py

spark-submit LowestRatedMovieSpark.py

PySpark 실습(터미널 환경)

maria_dev@sandbox-hdp:~

```
21/06/06 05:35:15 INFO MemoryStore: Block broadcast_5_piece0 stored as bytes in memory (es
21/06/06 05:35:15 INFO BlockManagerInfo: Added broadcast_5_piece0 in memory on sandbox-hdp
21/06/06 05:35:15 INFO SparkContext: Created broadcast 5 from broadcast at DAGScheduler.sc
21/06/06 05:35:15 INFO DAGScheduler: Submitting 1 missing tasks from ResultStage 6 (Python
21/06/06 05:35:15 INFO TaskSchedulerImpl: Adding task set 6.0 with 1 tasks
21/06/06 05:35:15 INFO TaskSetManager: Starting task 0.0 in stage 6.0 (TID 8, localhost, e
21/06/06 05:35:15 INFO Executor: Running task 0.0 in stage 6.0 (TID 8)
21/06/06 05:35:15 INFO ShuffleBlockFetcherIterator: Getting 2 non-empty blocks out of 2 bl
21/06/06 05:35:15 INFO ShuffleBlockFetcherIterator: Started 0 remote fetches in 0 ms
21/06/06 05:35:15 INFO PythonRunner: Times: total = 43, boot = -25, init = 67, finish = 1
21/06/06 05:35:15 INFO Executor: Finished task 0.0 in stage 6.0 (TID 8). 1773 bytes result
21/06/06 05:35:15 INFO TaskSetManager: Finished task 0.0 in stage 6.0 (TID 8) in 54 ms on
21/06/06 05:35:15 INFO TaskSchedulerImpl: Removed TaskSet 6.0, whose tasks have all comple
21/06/06 05:35:15 INFO DAGScheduler: ResultStage 6 (runJob at PythonRDD.scala:141) finishe
21/06/06 05:35:15 INFO DAGScheduler: Job 2 finished: runJob at PythonRDD.scala:141, took 0
('3 Ninjas: High Noon At Mega Mountain (1998)', 1.0)
('Beyond Bedlam (1993)', 1.0)
('Power 98 (1995)', 1.0)
('Bloody Child, The (1996)', 1.0)
('Amityville: Dollhouse (1996)', 1.0)
('Babyfever (1994)', 1.0)
('Homage (1995)', 1.0)
('Somebody to Love (1994)', 1.0)
('Crude Oasis, The (1995)', 1.0)
('Every Other Weekend (1990)', 1.0)
```

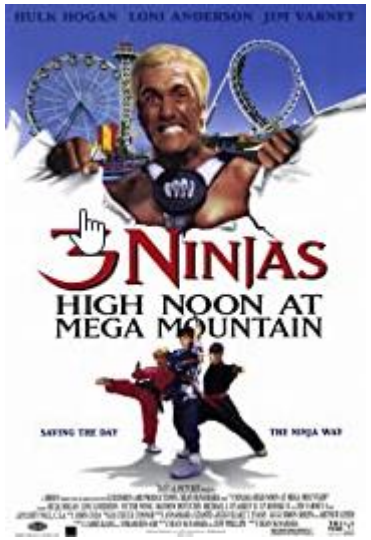

Colab에서 PySpark 사용하는 방법

spark_in_colab.ipynb

■ 방법 #1

```
!pip install pyspark py4j
```

■ 방법 #2

```
# !apt-get install openjdk-8-jdk-headless -qq
!wget -q !wget -q https://downloads.apache.org/spark/spark-3.3.2/spark-3.3.2-bin-hadoop3.tgz
!tar -xf spark-3.3.2-bin-hadoop3.tgz
!pip install -q findspark

import os
import findspark

os.environ["JAVA_HOME"] = "/usr/lib/jvm/java-8-openjdk-amd64"
os.environ["SPARK_HOME"] = "/content/spark-3.3.2-bin-hadoop3"

findspark.init()
findspark.find()
```

참조 : https://medium.com/@TheITspace/running-pyspark-on-google-colab-2552435972b3

PySpark RDD 실습

spark_rdd.ipynb

■ textFile() 메소드를 사용해 RDD 만들기

```
[7]  # licenses RDD에 전체 디렉토리의 내용 로드
     license_files = sc.textFile("file:///content/spark-3.3.2-bin-hadoop3/licenses/")
```

```
[8]  # 생성된 객체 검사
     license_files
```

```
file:///content/spark-3.3.2-bin-hadoop3/licenses/ MapPartitionsRDD[6] at textFile at NativeMethodAccessorImpl.java:0
```

```
[9]  license_files.take(1)
```

```
['<HTML>']
```

```
[10] license_files.getNumPartitions()
```

```
58
```

```
[11] # 모든 파일에서 총 라인 수
     license_files.count()
```

```
2998
```

PySpark RDD 실습

spark_rdd.ipynb

■ 데이터 소스에서 RDD 생성

```
[13] people = spark.read.json("/content/spark-3.3.2-bin-hadoop3/examples/src/main/resources/people.json")
```

```
[14] people
```

```
DataFrame[age: bigint, name: string]
```

```
[15] people.dtypes
```

```
[('age', 'bigint'), ('name', 'string')]
```

```
[16] people.show()
```

```
+----+-------+
| age|   name|
+----+-------+
|null|Michael|
|  30|   Andy|
|  19| Justin|
+----+-------+
```

```
[17] from pyspark.sql import SQLContext

     # as with all DataFrames you can create use them to run SQL queries as follows
     sqlContext = SQLContext(sc)
     sqlContext.registerDataFrameAsTable(people, "people")
     df2 = spark.sql("SELECT name, age FROM people WHERE age > 20")
     df2.show()
```

```
/content/spark-3.3.2-bin-hadoop3/python/pyspark/sql/context.py:112: FutureWarnin
  warnings.warn(
+----+---+
|name|age|
+----+---+
|Andy| 30|
+----+---+
```

PySpark RDD 실습

spark_rdd.ipynb

■ 프로그래밍 방식으로 RDD 생성

```
[18] parallel_rdd = sc.parallelize([0, 1, 2, 3, 4, 5, 6, 7, 8])
```

```
[19] parallel_rdd
```

```
ParallelCollectionRDD[21] at readRDDFromFile at PythonRDD.scala:274
```

```
[20] parallel_rdd.count()
```

```
9
```

```
[21] # 0에서 시작해서 1000개의 정수로, 2개의 파티션에서 1씩 증가하는 RDD 생성
     range_rdd = sc.range(0, 1000, 1, 2)
     range_rdd
```

```
PythonRDD[24] at RDD at PythonRDD.scala:53
```

```
[22] range_rdd.getNumPartitions()
```

```
2
```

PySpark DataFrame 실습

spark_dataframe.ipynb

■ 데이터 파일 : people.json

{"name":"Michael"}

{"name":"Andy", "age":30}

{"name":"Justin", "age":19}

■ Creating a DataFrame

```
[2]  from pyspark.sql import SparkSession
```

```
[3]  # May take a little while on a local computer
     spark = SparkSession.builder.appName("Basics").getOrCreate()
```

```
[4]  df = spark.read.json('people.json')
```

PySpark DataFrame 실습

spark_dataframe.ipynb

■ Showing the data

```
[5]  # Note how data is missing!
     df.show()
```

```
+----+-------+
| age|   name|
+----+-------+
|null|Michael|
|  30|   Andy|
|  19| Justin|
+----+-------+
```

```
[6]  df.printSchema()
```

```
root
 |-- age: long (nullable = true)
 |-- name: string (nullable = true)
```

```
[7]  df.columns
```

```
['age', 'name']
```

```
[8]  df.describe()
```

```
DataFrame[summary: string, age: string, name: string]
```

PySpark DataFrame 실습

spark_dataframe.ipynb

Infer schema

```
[9]  from pyspark.sql.types import StructField,StringType,IntegerType,StructType
```

```
[10] data_schema = [StructField("age", IntegerType(), True),StructField("name", StringType(), True)]
```

```
[11] final_struc = StructType(fields=data_schema)
```

```
[12] df = spark.read.json('people.json', schema=final_struc)
```

```
[13] df.printSchema()
```

```
root
 |-- age: integer (nullable = true)
 |-- name: string (nullable = true)
```

PySpark DataFrame 실습

spark_dataframe.ipynb

■ Grabbing the data

```
[14]  df['age']
```

```
Column<'age'>
```

```
[15]  type(df['age'])
```

```
pyspark.sql.column.Column
```

```
[16]  df.select('age')
```

```
DataFrame[age: int]
```

```
[17]  type(df.select('age'))
```

```
pyspark.sql.dataframe.DataFrame
```

```
[18]  df.select('age').show()
```

```
+----+
| age|
+----+
|null|
|  30|
|  19|
+----+
```

PySpark DataFrame 실습

spark_dataframe.ipynb

■ Multiple Columns

```
[20]  df.select(['age','name'])
```

```
DataFrame[age: int, name: string]
```

```
[21]  df.select(['age','name']).show()
```

```
+----+-------+
| age|   name|
+----+-------+
|null|Michael|
|  30|   Andy|
|  19| Justin|
+----+-------+
```

■ Creating new columns

```
[22]  # Adding a new column with a simple copy
      df.withColumn('newage',df['age']).show()
```

```
+----+-------+------+
| age|   name|newage|
+----+-------+------+
|null|Michael|  null|
|  30|   Andy|    30|
|  19| Justin|    19|
+----+-------+------+
```

PySpark DataFrame 실습

spark_dataframe.ipynb

■ More complicated operations to create new columns

```
[25]  df.withColumn('doubleage',df['age']*2).show()
```

```
+----+-------+---------+
| age|   name|doubleage|
+----+-------+---------+
|null|Michael|     null|
|  30|   Andy|       60|
|  19| Justin|       38|
+----+-------+---------+
```

```
[26]  df.withColumn('add_one_age',df['age']+1).show()
```

```
+----+-------+-----------+
| age|   name|add_one_age|
+----+-------+-----------+
|null|Michael|       null|
|  30|   Andy|         31|
|  19| Justin|         20|
+----+-------+-----------+
```

https://sparkbyexamples.com/pyspark-tutorial/

PySpark ML 실습

spark_linear_regression.ipynb

spark_logistic_regression.ipynb

spark_tree_model.ipynb

PySpark Tutorial

https://sparkbyexamples.com/pyspark-tutorial/

- What is PySpark
  - Introduction
  - Who uses PySpark
  - Features
  - Advantages
- PySpark Architecture
- Cluster Manager Types
- Modules and Packages
- PySpark Installation on windows
- Spyder IDE & Jupyter Notebook
- PySpark RDD
  - RDD creation
  - RDD operations
- PySpark DataFrame
  - Is PySpark faster than pandas?
  - DataFrame creation
  - DataFrame Operations
  - DataFrame external data sources
  - Supported file formats
- PySpark SQL
- PySpark Streaming
  - Streaming from TCP Socket
  - Streaming from Kafka
- PySpark GraphFrames
  - GraphX vs GraphFrames

Thank you

kgpark88@gmail.com